Che cosa è il Data Mining?

Risposta corretta:
Il processo che estrae nuova conoscenza o identifica pattern/modelli nei dati mediante l'applicazione di diversi algoritmi.

Che cosa è un pattern?

Risposta corretta:
Una espressione in un determinato linguaggio che descrive i fatti di un sottoinsieme di registrazioni presenti in un data base.

Quale fra le seguenti attività non fa parte del processo di KDD

Risposta corretta:
Nessuna delle altre alternative

👉 Perché: tutte le opzioni (Data Mining, Selezione, Interpretazione) fanno parte del KDD

Quale fra le seguenti attività non fa parte del processo di KDD?

Risposta corretta:
Intervista

👉 Non è una fase del KDD (le vere fasi sono selezione, pre-elaborazione, trasformazione, data mining, interpretazione/valutazione)

✍️ Quali sono le fasi caratteristiche del data mining?

Risposta:

Le fasi caratteristiche del data mining sono due:

- **Esplorazione dei dati**, che precede la scoperta di un modello valido e serve per analizzare i dati ed evidenziare eventuali errori nella preparazione ed estrazione.
- **Generazione dei pattern**, che utilizza regole e algoritmi per individuare modelli e associazioni nei dati, i quali devono poi essere validati e interpretati.

✍️ Cosa è una transazione?

Risposta:

Una transazione è una unità elementare di lavoro di un'applicazione a cui si vogliono associare caratteristiche di correttezza, robustezza ed isolamento.
Essa consiste in una sequenza di operazioni che può concludersi con successo o insuccesso: in caso di successo i risultati devono essere permanenti, mentre in caso di errore si deve tornare allo stato precedente all'inizio della transazione.

✍️ Quali sono le fasi del KDD?

Risposta:

Le fasi del processo di KDD sono:

- **Selezione**: estrazione dei dati rilevanti in base all'obiettivo.
- **Pre-elaborazione**: pulizia dei dati e rimozione di informazioni inutili o inconsistenti.
- **Trasformazione**: modifica e arricchimento dei dati per renderli utilizzabili.
- **Data mining**: estrazione di modelli e pattern dai dati.
- **Interpretazione e valutazione**: analisi dei risultati per ottenere conoscenza utile al supporto decisionale.

Perfetto, andiamo dritti al punto come prima 👇
(qui devi essere preciso perché queste sono **domande tipiche d'esame**)

Cosa si intende per knowledge elicitation?

Risposta corretta:
Il confronto fra gli esperti di uno specifico dominio e l'ingegnere della conoscenza al fine di aggiungere in fase di modellazione elementi che potrebbero non essere estraibili dai dati.

👉 Concetto chiave:
non tutto si trova nei dati → serve la conoscenza umana.

A cosa servono i modelli predittivi?

Risposta corretta:
Utilizzano i loro parametri e meccanismi caratteristici per effettuare delle previsioni future che possono essere utili nei processi decisionali.

👉 Esempio dalle slide: scoring, credit scoring

A cosa servono i modelli descrittivi?

Risposta corretta:
Vengono utilizzati per descrivere la struttura organizzativa e la distribuzione dei dati.
L'obiettivo di questi modelli è quello di approfondire la conoscenza nascosta dietro ai dati.

👉 Esempio: clustering, segmentazione clienti

Quali sono i pilastri operativi su cui si basa ogni algoritmo di data mining?

Risposta corretta:
Esplorazione, Modellazione, Valutazione

✍️ DOMANDE APERTE (qui devi saper parlare bene)

Differenza fra modelli predittivi e descrittivi

Risposta:

- I **modelli predittivi** servono a prevedere valori futuri o sconosciuti sulla base dei dati disponibili.
  Esempio: prevedere se un cliente acquisterà un prodotto.
- I **modelli descrittivi** servono a comprendere la struttura dei dati e individuare pattern nascosti senza fare previsioni.
  Esempio: segmentare i clienti in gruppi omogenei.

👉 Sintesi da dire all'esame:

- predittivi = previsione
- descrittivi = comprensione

Perché il processo di data mining è da considerarsi interattivo?

Risposta:

Il processo di data mining è interattivo perché:

- i risultati ottenuti vengono continuamente **valutati e interpretati**
- in base ai risultati si possono **modificare i dati, i parametri o gli algoritmi**
- si ripete il processo fino ad ottenere un modello soddisfacente

👉 Tradotto semplice:
non è lineare → si prova, si corregge, si ripete.

Quali sono i pilastri operativi su cui poggia il data mining?

Risposta:

I pilastri operativi del data mining sono:

- **Esplorazione**: analisi preliminare dei dati
- **Modellazione**: costruzione dei modelli (algoritmi)
- **Valutazione**: verifica della qualità e utilità dei risultati

👉 Questa è una domanda **molto frequente all'esame**

Cosa succede durante un addestramento supervisionato?

Risposta corretta:
✔️ *Vengono utilizzati dei dati etichettati, ovvero dove si conosce il valore dell'uscita desiderata, sia essa una classe o il valore di una funzione, a fronte di un ingresso specifico*

A cosa serve la cross validation?

Risposta corretta:
✔️ *A migliorare la capacità di generalizzazione dei modelli*

Che cosa è l'overfitting?

Risposta corretta:
✔️ *E' il fenomeno per cui in fase di addestramento un modello si adatta al campione osservato e perde la capacita di generalizzazione*

Cosa succede durante un addestramento non supervisionato?

Risposta corretta:
✔️ *I dati che si utilizzano non sono etichettati e gli algoritmi di apprendimento mirano ad estrarre la conoscenza (i parametri del modello) senza avere una specifica conoscenza del dominio del problema*

Quale è il dominio degli attributi categorici?

Risposta corretta:
✔️ *Nessuna delle altre alternative*

Discutere il processo della cross validation.

Risposta:

La cross validation è una tecnica utilizzata per valutare la capacità di generalizzazione di un modello, soprattutto quando il numero di dati a disposizione è limitato.

Il metodo più comune è la **K-fold cross validation**. In questo approccio, il dataset viene suddiviso in K sottoinsiemi (fold). Il modello viene addestrato K volte: ogni volta si utilizzano K-1 fold come training set e il fold rimanente come test set.

Questo processo viene ripetuto ciclicamente fino a quando ogni fold è stato utilizzato una volta come test set. Alla fine si calcola la media delle prestazioni ottenute (ad esempio errore o accuratezza), ottenendo così una stima più robusta delle performance del modello .

Esistono anche varianti come:

- la cross validation stratificata, che mantiene la distribuzione delle classi
- il leave-one-out, in cui ogni istanza viene usata una volta come test

Questa tecnica permette di ridurre la dipendenza dai dati e di ottenere una valutazione più affidabile del modello.

Elencare le differenze fra boosting e bagging.

Risposta:

Il bagging e il boosting sono tecniche di ensemble learning utilizzate per migliorare le prestazioni dei modelli, ma differiscono nel modo in cui vengono costruiti i modelli.

Nel **bagging**, si addestrano più modelli indipendenti utilizzando diversi sottoinsiemi dei dati ottenuti tramite campionamento con rimpiazzamento. Il risultato finale viene ottenuto combinando le predizioni dei modelli, generalmente tramite voto di maggioranza o media .

Nel **boosting**, invece, i modelli vengono addestrati in modo sequenziale. Ogni nuovo modello si concentra maggiormente sulle istanze che sono state classificate in modo errato dai modelli precedenti, assegnando loro un peso maggiore. Il risultato finale è una combinazione pesata dei modelli.

La differenza principale è che:

- nel bagging i modelli sono indipendenti
- nel boosting i modelli sono dipendenti e costruiti in sequenza

Discutere il problema dell'overfitting.

Risposta:

L'overfitting è un fenomeno che si verifica quando un modello si adatta eccessivamente ai dati di addestramento, imparando non solo le relazioni utili ma anche il rumore e le anomalie presenti nei dati.

Questo porta ad avere prestazioni molto elevate sul training set, ma scarse prestazioni su dati nuovi, indicando una bassa capacità di generalizzazione.

Le cause principali dell'overfitting possono essere:

- un modello troppo complesso
- un numero limitato di dati
- un addestramento troppo spinto

Per ridurre l'overfitting si possono adottare diverse tecniche, tra cui:

- la cross validation
- l'utilizzo di più dati
- la semplificazione del modello
- tecniche di regolarizzazione

In sintesi, l'overfitting rappresenta un problema critico perché compromette la capacità del modello di funzionare correttamente su dati reali.

Cosa sono gli istogrammi?

Risposta corretta:
✔️ *Sono dei diagrammi che consentono di visualizzare la frequenza con cui si distribuiscono i dati divisi in classi (banalmente in intervalli)*

Cosa sono gli scatter plot?

Risposta corretta:
✔️ *Sono dei grafici che consentono di verificare rapidamente se due variabili sono correlate (dipendenti linearmente) fra di loro*

Cosa sono i box plot?

Risposta corretta:
✔️ *Si tratta di visualizzazioni grafiche che consentono di sintetizzare con 5 valori le caratteristiche di una distribuzione. Tali valori sono: minimo, massimo, mediana, primo quartile, terzo quartile*

Che cosa è la mediana di una variabile casuale X?

Risposta corretta:
✔️ *E' un indice di posizione: una volta ordinati tutti i valori assunti da X, la mediana si calcola estraendo il valore del campione che divide la distribuzione in due popolazioni di eguali dimensioni*

Che cosa è la moda di una variabile casuale X?

Risposta corretta:
✔️ *E' l'indicatore che indica quale è il valore di X che si presenta più frequentemente nei dati*

Fornire un esempio di distribuzione e del suo istogramma

Risposta:

Un esempio di distribuzione può essere il numero di incidenti mensili in un anno:
(0, 1, 3, 4, 5, 2, 2, 6, 7, 2, 0, 1).

Per costruire l'istogramma, i valori vengono suddivisi in intervalli (classi) e per ciascun intervallo si conta la frequenza dei dati che ricadono al suo interno.

Ad esempio, come mostrato nelle slide (pagina 6), l'intervallo [0,7] può essere suddiviso in più sotto-intervalli di uguale ampiezza (es. 5 classi), e per ciascuna si rappresenta un rettangolo la cui altezza indica la frequenza.

L'istogramma permette quindi di visualizzare come i dati sono distribuiti e se sono concentrati in certe zone oppure distribuiti uniformemente.

Cosa si intende per outliers?

Risposta:

Gli outliers sono valori anomali che si discostano significativamente dal resto dei dati di una distribuzione.

Ad esempio, nella distribuzione mostrata nelle slide (pagina 4), i valori -10, 15 e 30 sono considerati outliers perché sono molto distanti dagli altri valori.

Gli outliers possono essere:

- errori di misurazione
- eventi rari
- dati particolari ma reali

Sono importanti perché possono influenzare fortemente analisi statistiche e modelli.

Quali sono gli indicatori di dispersione?

Risposta:

Gli indicatori di dispersione misurano quanto i dati sono dispersi rispetto a un valore centrale (come la media).

I principali indicatori sono:

- **Varianza**
- **Deviazione standard**
- **Range (campo di variazione)** → differenza tra massimo e minimo
- **Intervallo interquartile (IQR)** → differenza tra terzo e primo quartile

Questi indicatori permettono di capire se i dati sono concentrati oppure molto variabili.

Discutere la differenza fra quartile e quantile

Risposta:

I quantili sono valori che dividono una distribuzione ordinata in parti uguali.

I quartili sono un caso particolare di quantili:

- dividono i dati in 4 parti uguali
- Q1 (25%), Q2 (mediana, 50%), Q3 (75%)

In generale:

- i **quantili** dividono la distribuzione in qualsiasi numero di parti (es. percentili → 100 parti)
- i **quartili** sono specifici per la divisione in 4 parti

Quindi:
👉 tutti i quartili sono quantili
👉 ma non tutti i quantili sono quartili

Quali fra i seguenti passaggi non fanno parte della pre-elaborazione dei dati?

Risposta corretta:
✔️ *Nessuna delle altre alternative*

Quali fra i seguenti passaggi non fanno parte della pre-elaborazione dei dati?

Risposta corretta:
✔️ *Gestione dei dati*

Cosa si intende per riduzione della dimensionalità?

Risposta corretta:
✔️ *Si parla di riduzione dimensionale quando vengono applicate delle tecniche per codificare i dati secondo degli schemi precisi al fine di ottenere una rappresentazione compressa o ridotta dei dati originali (esempio uso di Trasformate o tecniche di selezione di attributi).*

Quali sono i principali fattori che caratterizzano la qualità dei dati?

Risposta:

I principali fattori che caratterizzano la qualità dei dati riguardano diversi aspetti fondamentali che permettono di stabilire quanto un dato sia affidabile e utilizzabile in un processo di analisi. In primo luogo, l'accuratezza indica quanto un dato sia corretto rispetto alla realtà, considerando che errori possono derivare sia da malfunzionamenti tecnici sia da inserimenti errati. La completezza riguarda invece la presenza di tutte le informazioni necessarie, poiché dati mancanti possono compromettere l'analisi. Un altro aspetto importante è la consistenza, che verifica l'assenza di contraddizioni tra dati provenienti da fonti diverse. A questi si aggiungono la tempo-invarianza, che misura quanto i dati siano aggiornati, la credibilità, che riflette il livello di fiducia che gli utenti attribuiscono ai dati, e infine l'interpretabilità, cioè la facilità con cui i dati possono essere compresi e utilizzati.

Perché è necessario il trattamento preliminare dei dati?

Risposta:

Il trattamento preliminare dei dati è necessario perché, nella maggior parte dei casi reali, i dati disponibili non sono immediatamente pronti per essere analizzati. Essi provengono spesso da fonti diverse e possono contenere errori, rumore, valori mancanti o incoerenze. Se questi problemi non vengono affrontati, l'applicazione di tecniche di data mining potrebbe produrre risultati poco affidabili o addirittura fuorvianti. Per questo motivo è fondamentale intervenire con operazioni di pulizia, integrazione, trasformazione e riduzione dei dati, in modo da migliorarne la qualità complessiva. Come evidenziato nelle slide, una corretta pre-elaborazione consente non solo di eliminare anomalie e ridurre il rumore, ma anche di ottenere risultati più accurati e significativi nelle fasi successive di analisi.

Fornire un esempio in cui potrebbe essere necessario effettuare data cleaning o data integration

Risposta:

Un esempio in cui è necessario effettuare data cleaning si verifica quando un dataset contiene valori mancanti, errori o dati anomali. Si pensi, ad esempio, a un database di clienti in cui alcune età risultano assenti oppure assumono valori non realistici, come 200 anni. In questi casi è necessario intervenire per correggere o sostituire tali valori, così da rendere il dataset coerente e utilizzabile. Un caso tipico di data integration, invece, si presenta quando si devono unire dati provenienti da più sorgenti. Può accadere, ad esempio, che lo stesso cliente venga registrato con nomi leggermente diversi in due database distinti, come “Bill Clinton” in uno e “William Clinton” in un altro. In queste situazioni è necessario uniformare le informazioni per evitare duplicazioni e incoerenze, garantendo così una visione corretta e unificata dei dati.

Quali fra le seguenti tecniche non si usano in fase di gestione dei missing value?

Risposta corretta:
✔️ *Nessuna delle altre alternative*

L'analisi degli outlier può essere usata per:

Risposta corretta:
✔️ *Identificare e gestire i dati rumorosi*

L'analisi in regressione può essere usata per:

Risposta corretta:
✔️ *Identificare e gestire i dati rumorosi*

Con quali tecniche si gestiscono i missing value?

Risposta corretta:
✔️ *Data cleaning*

Le fasi del processo di data cleaning si effettuano solo una volta. Vero o falso? Discutere la scelta effettuata.

Risposta:

L’affermazione è falsa, perché il processo di data cleaning non è un’attività che si svolge una sola volta in modo lineare, ma è invece iterativo. Nella pratica, dopo aver individuato e corretto alcune discrepanze, possono emergere nuovi problemi che prima non erano visibili. Inoltre, alcune trasformazioni applicate ai dati possono introdurre ulteriori errori o anomalie, rendendo necessario un nuovo ciclo di verifica e correzione. Come evidenziato nelle slide, il

processo può dover essere ripetuto più volte fino a quando i dati raggiungono un livello di qualità soddisfacente. Questo rende il data cleaning un’attività complessa e spesso lunga, ma fondamentale per ottenere risultati affidabili nelle analisi successive.

Cosa si intende per Data Scrubbling e Data Auditing?

Risposta:

Con il termine data scrubbing si fa riferimento a un insieme di tecniche che utilizzano una conoscenza di base del dominio per individuare e correggere errori nei dati. Si tratta, ad esempio, di controlli su codici postali, formati standard o errori ortografici, che permettono di identificare rapidamente anomalie evidenti e correggerle in modo automatico o semi-automatico. Il data auditing, invece, rappresenta un approccio più analitico, in cui i dati vengono esaminati per scoprire regole, pattern e relazioni interne. In questo caso, le discrepanze vengono individuate quando alcune tuple non rispettano tali regole, spesso tramite tecniche come correlazione o clustering. In sostanza, mentre il data scrubbing lavora su errori più superficiali e basati su conoscenza predefinita, il data auditing si concentra su una comprensione più profonda dei dati.

Descrivere la seconda fase del processo di data cleaning, specificando che tipi di tool commerciali potrebbero essere utilizzati.

Risposta:

La seconda fase del processo di data cleaning interviene dopo che sono state individuate le discrepanze nei dati e consiste nella loro correzione attraverso opportune trasformazioni. In questa fase si definiscono e applicano delle operazioni che permettono di rendere i dati coerenti, uniformi e utilizzabili. Queste trasformazioni possono riguardare, ad esempio, la modifica di valori, la standardizzazione di formati o la sostituzione di informazioni errate. Per supportare queste attività esistono diversi strumenti commerciali. Alcuni sono dedicati alla migrazione dei dati e permettono di effettuare trasformazioni semplici, come la sostituzione di un termine con un altro. Altri, più avanzati, sono i tool ETL, che consentono di eseguire operazioni di estrazione, trasformazione e caricamento dei dati attraverso interfacce grafiche intuitive, rendendo il processo più accessibile anche a utenti non esperti.

Quali sono i passaggi per effettuare l'eliminazione delle discrepanze fra i dati?

Risposta:

L’eliminazione delle discrepanze tra i dati parte da una fase di analisi in cui si definiscono chiaramente le caratteristiche degli attributi attraverso i metadati, specificando dominio, intervallo e relazioni tra i dati. Successivamente, è necessario verificare che non vi siano utilizzi impropri dei campi, come nel caso dell’overloading, in cui uno stesso spazio viene

riutilizzato per informazioni diverse. Un altro passaggio fondamentale riguarda il controllo delle regole di integrità, come l'unicità dei valori, che evita duplicazioni, la consecutività, che garantisce l'assenza di valori mancanti in sequenze numeriche, e la corretta gestione dei valori nulli. Attraverso questi controlli è possibile individuare le anomalie e intervenire per correggerle, migliorando la qualità complessiva del dataset.

Quali sono i passi da effettuare nel processo di data integration?

Risposta corretta:
✔️ *Identificazione delle entità, Identificazione e risoluzione dei conflitti nei dati, identificazione delle ridondanze*

Qual è l'obiettivo principale della fase di data integration?

Risposta corretta:
✔️ *Ottenere una memorizzazione coerente per i dati derivanti da sorgenti multiple*

👉 Tradotto semplice: prendere dati da fonti diverse e farli "parlare la stessa lingua".

Per quale fase si può utilizzare l'analisi di correlazione nel processo di data integration?

Risposta corretta:
✔️ *Identificazione delle ridondanze*

👉 Se due attributi sono molto correlati → probabilmente sono ridondanti.

Quali sono i conflitti che possono apparire nei dati?

Risposta:

Durante la data integration possono emergere diversi tipi di conflitti tra dati provenienti da sorgenti diverse:

- **Conflitti di naming (schema):**
  stessi dati con nomi diversi (es. "ID_cliente" vs "CustomerID")
- **Conflitti semantici:**
  stesso nome ma significato diverso
- **Conflitti di formato:**
  date, unità di misura, valute diverse
- **Conflitti di rappresentazione:**
  es. "M/F" vs "Maschio/Femmina"

- **Conflitti di valore (data conflict):**
  stessi oggetti ma valori diversi (es. due indirizzi diversi per lo stesso cliente)

Quando si parla di data integration, cosa sono e come si usano i metadati?

Risposta:

I **metadati** sono dati che descrivono altri dati.

👉 Servono per capire:

- struttura (tipo di campo, formato)
- significato (cosa rappresenta)
- relazioni tra dati

Nel data integration vengono usati per:

- allineare dati provenienti da fonti diverse
- risolvere ambiguità
- mappare correttamente gli attributi

In pratica: **sono la guida per integrare correttamente i dati**.

Cosa si intende per identificazione delle ridondanze? Come si possono gestire?

Risposta:

L'identificazione delle ridondanze consiste nel trovare dati duplicati o informazioni che esprimono lo stesso concetto.

Esempio:

- "età" e "data di nascita" → correlati → uno può essere inutile

👉 Tecniche per individuarle:

- analisi di correlazione (numerici)
- confronto tra attributi
- analisi statistica

👉 Gestione:

- eliminare attributi duplicati
- mantenere solo uno dei due
- creare un attributo derivato

Come mostrato nelle slide, la correlazione (es. Pearson) è usata proprio per capire se due attributi sono legati e quindi ridondanti

Cos'è il test del chi quadro? Come può essere utilizzato nella fase di data integration?

Risposta:

Il **test del chi-quadro (χ^2)** è un test statistico che serve per verificare se due variabili sono indipendenti oppure correlate.

👉 In parole semplici:

- controlla se due attributi sono collegati o no

👉 Nel data integration viene usato per:

- analizzare attributi **categorici (nominali)**
- identificare ridondanze
- capire se due campi rappresentano la stessa informazione

Esempio:

- "tipo cliente" e "categoria utente"
  → se risultano fortemente dipendenti → possibile ridondanza

Hai ragione, qui ho sbagliato io.

Da adesso seguo **questo formato fisso** senza perdermi:

- **testo esatto della domanda**
- per le **domande chiuse**: **testo esatto della risposta corretta**
- per le **domande aperte**: **testo esatto della domanda** + **risposta più articolata e discorsiva**, evitando gli elenchi **quando possibile**

Ti riscrivo subito la **Lezione 009** nel formato corretto.

Lezione 009

Cosa si intende per riduzione dei dati lossy?

Risposta corretta:
La tecnica utilizzata per la riduzione consente di ricostruire i dati originali solo tramite una approssimazione degli stessi

Per cosa può essere utilizzata la principal component analysis?

Risposta corretta:
Riduzione della dimensionalità

Cosa si intende per riduzione dei dati lossless?

Risposta corretta:
La tecnica utilizzata consente di ricostruire i dati originali da quelli ridotti senza alcuna perdita di informazione

Per cosa può essere utilizzata la trasformata discreta wavelet?

Risposta corretta:
Riduzione della dimensionalità

Discutere la trasformata discreta wavelet e suoi vantaggi

Risposta:

La trasformata discreta wavelet, indicata con l'acronimo DWT, è una trasformazione lineare applicata ai segnali che consente di rappresentare i dati in un nuovo spazio attraverso coefficienti wavelet. In pratica, partendo da un vettore di campioni del segnale, si ottiene un nuovo vettore di coefficienti che permette di descrivere il segnale in modo diverso rispetto alla forma originale. L'aspetto più interessante, dal punto di vista della riduzione dei dati, è che non tutti i coefficienti ottenuti hanno la stessa importanza: quelli più significativi vengono mantenuti, mentre quelli meno rilevanti possono essere eliminati o posti a zero, ottenendo così una forte compressione dei dati e una buona approssimazione del segnale originale. Questo rende la DWT particolarmente utile non solo per ridurre la dimensionalità, ma anche per diminuire il rumore presente nei dati. Le slide sottolineano inoltre che la DWT presenta diversi vantaggi rispetto alla trasformata discreta di Fourier, perché consente una compressione migliore, richiede meno spazio a parità di approssimazione, non perde informazioni spaziali e offre maggiore flessibilità grazie alla possibilità di scegliere diverse wavelet base.

Discutere il problema della dimensionalità e come la riduzione dei dati aiuta a risolverlo.

Risposta:

Il problema della dimensionalità nasce quando i dati sono descritti da un numero molto elevato di attributi. All'aumentare delle dimensioni, infatti, i dati tendono a diventare sempre più sparsi e questo rende più difficile interpretare correttamente concetti come distanza e densità tra i punti. Di conseguenza, tecniche molto importanti nel data mining, come il clustering o l'analisi degli outlier, diventano meno efficaci, perché in spazi molto grandi è complicato stabilire se due punti siano realmente vicini oppure lontani. Inoltre, cresce in modo esponenziale il numero delle possibili combinazioni di sottospazi e aumenta anche il costo computazionale dell'analisi. La riduzione dei dati interviene proprio per affrontare questo problema, perché consente di ottenere una rappresentazione più compatta dell'insieme originale mantenendo però le informazioni più importanti. In questo modo si eliminano attributi poco rilevanti o rumorosi, si riducono tempo e spazio richiesti dagli algoritmi di data mining e si migliora anche la leggibilità dei risultati. Le slide evidenziano proprio che la riduzione della dimensionalità serve a evitare i problemi legati all'eccesso di attributi, migliorando l'efficienza dell'analisi senza compromettere la qualità finale.

Discutere l'idea di base della PCA

Risposta:

L'idea di base della PCA, cioè dell'Analisi a Componenti Principali, è quella di trasformare un insieme di variabili originali in un nuovo sistema di riferimento formato da nuove variabili, dette componenti principali. Queste nuove variabili non coincidono con quelle iniziali, ma sono combinazioni lineari delle variabili originali. Il procedimento parte da dati descritti in n dimensioni e cerca di individuare, attraverso la matrice di covarianza, gli autovettori che definiscono le direzioni più significative del nuovo spazio. Le componenti principali vengono poi ordinate in base alla loro importanza, cioè in base a quanta varianza dei dati riescono a spiegare. A questo punto è possibile mantenere solo le componenti più rilevanti ed eliminare quelle meno importanti, ottenendo così una riduzione della dimensionalità. Il vantaggio della PCA è che permette di sintetizzare l'informazione contenuta nei dati in un numero minore di dimensioni, mantenendo però inalterate le caratteristiche più importanti del dataset. Le slide chiariscono che il nuovo spazio è identificato da k vettori ortogonali, con k minore o uguale a n, che possono essere usati per rappresentare efficacemente i dati originali.

Quali sono i casi in cui conviene maggiormente usare la PCA oppure la trasformata discreta wavelet?

Risposta:

La scelta tra PCA e trasformata discreta wavelet dipende soprattutto dal tipo di dati e dal problema che si vuole affrontare. La PCA risulta particolarmente conveniente quando si lavora con dataset numerici e si vuole ridurre la dimensionalità cercando di preservare la varianza più importante dei dati. È considerata anche poco costosa dal punto di vista computazionale e, come riportato nelle slide, tende ad essere più adatta alla gestione di dati sparsi, distorti e multidimensionali. La trasformata discreta wavelet, invece, è particolarmente utile quando si lavora con segnali o dati in cui è importante ottenere compressione e riduzione del rumore. Le slide specificano che la DWT è spesso usata in

applicazioni reali come la compressione di immagini e filmati, l’analisi di serie temporali e operazioni di data cleaning. Inoltre, nel confronto diretto tra le due tecniche, viene evidenziato che la PCA tende a essere migliore per dati sparsi, mentre la DWT è più adatta per dati di elevata dimensionalità. Per questo motivo, quando il problema principale è la sintesi statistica e la riduzione di variabili numeriche correlate, la PCA è spesso la scelta migliore; quando invece conta di più comprimere, filtrare o trattare segnali complessi e rumorosi, la wavelet risulta più vantaggiosa.

Quali fra le seguenti sono tecniche parametriche per la riduzione della numerosità?

Risposta corretta:
Regressione lineare e modelli log-lineari

La selezione degli attributi è in sostanza in problema di:

Risposta corretta:
Ottimizzazione

Nella strategia di selezione in avanti, il processo di selezione di attributi in genere comincia con:

Risposta corretta:
Un insieme iniziale di attributi vuoto

Nella strategia di selezione all'indietro, il processo di selezione di attributi in genere comincia con:

Risposta corretta:
Un insieme iniziale contenente tutti gli attributi

Quale fra le seguenti non è una tecnica non parametrica per la riduzione della numerosità?

Risposta corretta:
Regressione lineare e modelli log-lineari

Quali delle seguenti tecniche di classificazione possono essere usate anche per la selezione degli attributi?

Risposta corretta:
Alberi di decisione

Discutere la mutua informazione fra due attributi/variabili e spiegare come può essere utilizzata nel processo di selezione di attributi.

Risposta:

La mutua informazione è una misura che quantifica quanto due variabili condividono informazione, cioè quanto la conoscenza di una riduce l'incertezza sull'altra. Formalmente si basa sul concetto di entropia e viene calcolata come differenza tra le entropie delle singole variabili e la loro entropia congiunta. Questo significa che se due variabili sono indipendenti la mutua informazione è pari a zero, mentre aumenta al crescere della dipendenza tra di esse.

Nel contesto della selezione degli attributi, la mutua informazione viene utilizzata per valutare quanto ogni attributo sia rilevante rispetto alla variabile di output. In pratica, si calcola la mutua informazione tra ciascun attributo e la variabile target e si selezionano quelli che presentano i valori più alti, perché sono quelli che contribuiscono maggiormente alla previsione. Inoltre, può essere usata anche durante la ricerca del miglior sottoinsieme di attributi, come criterio per decidere quali attributi aggiungere o mantenere, permettendo di costruire modelli più semplici ma comunque informativi.

Cosa si intende per attributi ridondanti e irrilevanti?

Risposta:

Gli attributi irrilevanti sono quelli che non hanno alcuna relazione significativa con la variabile di output e quindi non contribuiscono alla capacità predittiva del modello. Gli attributi ridondanti, invece, sono quelli che forniscono informazioni già contenute in altri attributi, risultando quindi duplicati dal punto di vista informativo. La presenza di questi attributi può peggiorare le prestazioni degli algoritmi di data mining, aumentando la complessità del modello, il tempo di calcolo e il rischio di overfitting, oltre a rendere più difficile l'interpretazione dei risultati.

Discutere le differenze fra metodi wrapper e metodi filter per la selezione di attributi.

Risposta:

I metodi filter selezionano gli attributi basandosi su caratteristiche intrinseche dei dati, come ad esempio correlazione o mutua informazione, senza coinvolgere direttamente un algoritmo di apprendimento. Questo li rende generalmente più veloci e scalabili, ma anche meno accurati in alcuni casi, perché non tengono conto delle prestazioni effettive di un modello.

I metodi wrapper, invece, utilizzano direttamente un algoritmo di machine learning per valutare diversi sottoinsiemi di attributi, scegliendo quelli che producono le migliori prestazioni del modello. Questo approccio tende a essere più preciso, perché ottimizza rispetto al modello finale, ma è anche molto più costoso dal punto di vista computazionale.

Cosa si intende per metodo greedy?

Risposta:

Un metodo greedy è una strategia di ottimizzazione che costruisce una soluzione passo dopo passo, scegliendo ad ogni iterazione l'opzione che sembra la migliore in quel momento, senza considerare tutte le possibili combinazioni future. Questo tipo di approccio è molto utilizzato nei problemi di selezione degli attributi, ad esempio nelle strategie forward selection e backward elimination, perché permette di ridurre drasticamente lo spazio di ricerca. Tuttavia, non garantisce di trovare sempre la soluzione ottima globale, ma spesso fornisce una soluzione buona in tempi molto più rapidi.

A cosa serve la normalizzazione dei dati?

Risposta corretta:
Viene spesso utilizzata nella fase di data transformation per fare in modo che tutti gli attributi abbiano lo stesso peso o influenza

Se una tecnica di discretizzazione dei dati utilizza le etichette delle classi e le informazioni da esse derivanti di che tipologia è?

Risposta corretta:
Supervisionata

Cosa si intende per splitting?

Risposta corretta:
È fase di un processo di discretizzazione in cui si identificano ricorsivamente uno o più punti in cui suddividere gli intervalli di definizione degli attributi

Discutere una tecnica per la generazione di gerarchie di concetti per dati nominali.

Risposta:

Una tecnica consiste nella **specifica manuale di un ordinamento gerarchico tra attributi da parte di un esperto del dominio**. In questo approccio, l'utente definisce un ordine (anche parziale) tra gli attributi, stabilendo quali rappresentano livelli più generali e quali più specifici.

Ad esempio, si può definire una gerarchia come:
Regione > Città > Strada

Questo significa che "Regione" è un livello più alto (più generale), mentre "Strada" è il più dettagliato. Questo metodo è semplice ed efficace quando si dispone di conoscenza del dominio.

Cosa sono le gerarchie di concetti? Per cosa possono essere utili?

Risposta:

Le gerarchie di concetti sono strutture che organizzano i valori degli attributi in livelli gerarchici, passando da un livello dettagliato a uno più generale.

Servono principalmente a:

- Ridurre la complessità dei dati
- Facilitare l'analisi a diversi livelli di granularità
- Supportare operazioni di generalizzazione nei data warehouse

Ad esempio, un'età numerica può essere trasformata in categorie come "giovane", "adulto", "senior". Questo permette di semplificare l'analisi e individuare pattern più facilmente.

Discutere la discretizzazione dei dati e la tassonomia delle tecniche esistenti.

Risposta:

La discretizzazione è il processo di trasformazione di attributi numerici continui in intervalli discreti (bin), rendendo i dati più semplici da analizzare.

Le principali categorie sono:

- **Supervisionata vs non supervisionata**
    - Supervisionata: utilizza le classi (es. entropia, information gain)

    - Non supervisionata: non usa le classi (es. equal-width, equal-frequency)
- **Top-down (splitting) vs bottom-up (merging)**
    - Splitting: divide ricorsivamente gli intervalli
    - Merging: unisce intervalli inizialmente piccoli
- **Basata su metodi**
    - Binning
    - Clustering
    - Entropia/information gain

La discretizzazione è fondamentale perché migliora l'efficienza degli algoritmi e può aumentare la qualità dei modelli.

Cosa si intende per data transformation e quali sono le principali tecniche ad essa collegate?

Risposta:

La data transformation è la fase del preprocessing in cui i dati vengono trasformati per renderli più adatti all'analisi e al data mining.

Le principali tecniche includono:

- **Normalizzazione:** porta i dati su una scala comune
- **Discretizzazione:** trasforma valori continui in categorie
- **Aggregazione:** combina più dati in uno (es. media)
- **Costruzione di attributi:** crea nuove feature a partire da quelle esistenti
- **Gerarchie di concetti:** generalizza i dati su più livelli

Nella formula della distanza di Mahalanobis che tipo di matrice è presente?

Risposta corretta:
Di covarianze fra i due punti

👉 Dalla slide (pag. 7):

> "S(i,j) rappresenta la matrice delle covarianze"

La distanza Manhattan è un caso particolare di quale distanza?

Risposta corretta:
Minkowski

👉 Dalla slide (pag. 5):

- h = 1 → Manhattan
- h = 2 → Euclidea

Quali sono le proprietà della distanza Minkowski?

Risposta corretta:
Definita positiva, simmetrica e gode di diseguaglianza triangolare

- Positività
- Simmetria
- Diseguaglianza triangolare

Definire la distanza di Minkowski e discutere le sue proprietà.

Risposta:

La distanza di Minkowski è una misura di distanza definita tra due punti in uno spazio p-dimensionale e rappresenta una generalizzazione di diverse metriche utilizzate nel data mining. Essa viene calcolata considerando le differenze tra le componenti dei due vettori, elevate a una certa potenza h, e successivamente applicando una radice di ordine h al risultato complessivo. Il parametro h, chiamato ordine della distanza, è fondamentale perché determina il comportamento della misura e il modo in cui le differenze tra le variabili vengono pesate.

Dal punto di vista teorico, la distanza di Minkowski soddisfa le principali proprietà che caratterizzano una distanza metrica. In particolare, è sempre non negativa e assume valore zero solo quando i due punti coincidono, è simmetrica perché la distanza tra i due punti non dipende dall'ordine con cui vengono considerati e soddisfa la diseguaglianza triangolare, che garantisce coerenza geometrica nella misura delle distanze. Proprio per queste proprietà, la distanza di Minkowski viene classificata come una metrica ed è ampiamente utilizzata nei modelli di data mining che richiedono il calcolo di distanze tra osservazioni.

Cosa si intende per ordine della distanza Minkowski?

Risposta:

L'ordine della distanza di Minkowski, indicato con il parametro h, rappresenta il valore che determina il modo in cui vengono aggregate le differenze tra le componenti dei vettori considerati. Questo parametro ha un ruolo centrale perché modifica il comportamento della distanza stessa, influenzando la sensibilità alle differenze tra le variabili. All'aumentare dell'ordine, infatti, le differenze più grandi tendono ad avere un peso maggiore rispetto a quelle più piccole.

Nelle slide viene esplicitamente indicato che h rappresenta l'ordine della distanza, chiamata anche norma Lh, e che al variare di questo parametro si ottengono diverse metriche. Questo significa che la distanza di Minkowski non è una singola distanza, ma una famiglia di

distanze, ognuna con caratteristiche specifiche che dipendono proprio dal valore scelto per h.

Quali sono le altre distanze che si ottengono al variare dell'ordine della distanza Minkowski?

Risposta:

Al variare dell'ordine h della distanza di Minkowski si ottengono diverse distanze note, ciascuna con caratteristiche specifiche e con un diverso modo di misurare la distanza tra i punti. Quando l'ordine è pari a 1 si ottiene la distanza Manhattan, che calcola la distanza come somma delle differenze assolute tra le componenti dei vettori e viene spesso interpretata come la distanza percorsa in una griglia urbana. Quando l'ordine è pari a 2 si ottiene la distanza euclidea, che corrisponde alla distanza geometrica classica nello spazio e rappresenta la lunghezza del segmento che unisce due punti.

Se invece si considera il caso limite in cui l'ordine tende all'infinito, si ottiene la distanza di Lagrange-Tchebychev, che misura la distanza come la massima differenza tra le componenti dei due vettori. Questo significa che la distanza è determinata esclusivamente dalla dimensione in cui i due punti differiscono di più. Le slide mostrano chiaramente questi casi speciali e sottolineano come la distanza di Minkowski rappresenti una struttura unificante che permette di ottenere diverse metriche a seconda del valore scelto per il parametro h.

Che tipo di distanza si può utilizzare fra due punti descritti da variabili binarie asimmetriche?

Risposta corretta:
Jaccard

👉 Dalle slide: per variabili binarie asimmetriche si usa la distanza di Jaccard

Che tipo di distanza si può utilizzare fra due punti descritti da variabili binarie simmetriche?

Risposta corretta:
SMC

👉 Dalle slide: per variabili simmetriche si usa lo Simple Matching Coefficient

Quando una variabile binaria si dice simmetrica?

Risposta corretta:
Se la probabilità che ciascuno dei suoi stati si verifichi (che assuma valore zero o uno) è uguale ed entrambi gli stati assumono lo stesso peso

👉 Definizione diretta dalla slide sulle variabili binarie

Discutere i passaggi per calcolare la distanza fra due vettori che contengono variabili ordinali

Risposta:

Quando si ha a che fare con variabili ordinali, il problema principale è che i valori non sono numerici ma possiedono comunque un ordine. Per questo motivo, il primo passo consiste nel trasformare ciascun valore categorico in un numero che rappresenti la sua posizione all'interno dell'ordinamento, cioè un rango. In altre parole, si assegna a ogni valore un indice che riflette il suo livello relativo rispetto agli altri possibili valori della stessa variabile.

Successivamente, questi ranghi non possono essere utilizzati direttamente, perché potrebbero avere scale diverse tra le variabili. Si procede quindi con una normalizzazione che riporta tutti i valori in un intervallo comune, tipicamente tra 0 e 1. Questo passaggio è fondamentale per evitare che alcune variabili abbiano un'influenza maggiore di altre nel calcolo della distanza.

Una volta ottenuti i valori normalizzati, le variabili ordinali vengono trattate come variabili numeriche. A questo punto si può applicare una qualsiasi misura di distanza standard, come ad esempio la distanza euclidea o di Minkowski, utilizzando i valori trasformati. Le slide mostrano chiaramente questo processo, evidenziando il passaggio dal valore originale al rango e poi alla normalizzazione prima del calcolo finale della distanza.

Quale è la differenza fra la distanza e la similarità di Jaccard?

Risposta:

La distanza e la similarità di Jaccard sono due misure strettamente collegate ma concettualmente opposte. La distanza di Jaccard misura quanto due vettori sono diversi tra loro, considerando solo le componenti in cui almeno uno dei due presenta valore positivo. In particolare, si basa sul rapporto tra il numero di disaccordi e il numero totale di componenti rilevanti, cioè escludendo i casi in cui entrambi i valori sono zero.

La similarità di Jaccard, invece, misura quanto i due vettori sono simili e si concentra sul numero di componenti in cui entrambi assumono valore 1 rispetto al totale delle componenti significative. Nelle slide viene evidenziato chiaramente che la similarità di Jaccard è pari a uno meno la distanza di Jaccard, il che rende le due misure complementari tra loro. Questo significa che quando la similarità è alta la distanza è bassa e viceversa, offrendo due prospettive diverse sullo stesso fenomeno.

Cosa si intende per ranking di una variabile ordinale.

Risposta:

Il ranking di una variabile ordinale consiste nell'assegnare a ciascun valore possibile della variabile un numero intero che rappresenta la sua posizione all'interno di un ordinamento. Questo processo è necessario perché le variabili ordinali, pur non essendo numeriche, possiedono una relazione d'ordine tra i loro valori, come ad esempio basso, medio e alto.

Attribuendo un rango a ciascun valore, si trasforma la variabile in una forma numerica che mantiene l'informazione sull'ordine ma non sulle distanze reali tra i valori. Questo passaggio è fondamentale per poter utilizzare tecniche matematiche di analisi, come il calcolo delle distanze, che richiedono dati numerici. Le slide mostrano proprio che ogni valore viene trasformato in un rango appartenente a un insieme discreto, che poi viene utilizzato nelle fasi successive di normalizzazione e calcolo della distanza

La formula della similarità coseno fra due vettori utilizza al suo interno?

Risposta corretta:
La norma dei due vettori e il prodotto scalare fra i due vettori

👉 Dalle slide:
[
sim(d_1, d_2) = \frac{d_1 \cdot d_2}{||d_1|| , ||d_2||}
]

E' possibile calcolare la distanza fra istanze descritte da attributi nominali?

Risposta corretta:
Si utilizzando una distanza basata sul matching

👉 Simple Matching (conteggio delle uguaglianze)

Che tipo di distanza si può usare fra due istanze descritti con attributi di tipologia mista?

Risposta corretta:
Nessuna delle altre alternative

👉 Si usa una **formula specifica per dati misti**, non Euclidea/Minkowski standard

Discutere come si calcola la distanza fra oggetti descritti con attributi di tipologia mista

Risposta:

Quando gli oggetti sono descritti da attributi di tipologia mista, cioè una combinazione di variabili numeriche, binarie, nominali e ordinali, non è possibile applicare direttamente una distanza standard come quella euclidea. Si utilizza invece una misura che combina contributi diversi per ciascun attributo, costruendo una distanza complessiva come media pesata dei contributi delle singole variabili.

Per ogni attributo si calcola una distanza parziale tra i due oggetti. Se l'attributo è nominale o binario, la distanza vale zero se i valori coincidono e uno se sono diversi. Se l'attributo è numerico, si utilizza una distanza normalizzata, che tiene conto del range della variabile nel dataset, in modo da evitare che variabili con scale diverse influenzino eccessivamente il risultato. Se l'attributo è ordinale, si trasforma prima in un rango e poi si normalizza, trattandolo come una variabile numerica.

Tutti questi contributi vengono poi combinati tramite una media pesata. I pesi servono a escludere dal calcolo eventuali valori mancanti oppure casi particolari, come alcune variabili binarie asimmetriche in cui la coincidenza di zeri non è informativa. Il risultato finale è quindi una distanza globale che tiene conto in modo coerente della natura eterogenea degli attributi.

Come si calcola la similarità coseno e in che contesto si utilizza?

Risposta:

La similarità coseno si calcola come il rapporto tra il prodotto scalare di due vettori e il prodotto delle loro norme. In pratica, misura il coseno dell'angolo tra i due vettori nello spazio multidimensionale. Questo significa che non considera tanto la lunghezza dei vettori, ma la loro direzione. Due vettori sono molto simili se puntano nella stessa direzione, anche se hanno magnitudini diverse.

Questa misura viene utilizzata soprattutto quando gli oggetti sono descritti tramite frequenze, come nel caso dei documenti di testo. In questo contesto, ogni documento viene rappresentato come un vettore in cui ogni dimensione corrisponde a una parola e il valore indica quante volte quella parola compare. La similarità coseno permette di confrontare documenti ignorando la loro lunghezza e concentrandosi sul contenuto, cioè sulle parole condivise e sulla loro distribuzione.

Le slide mostrano proprio questo caso applicativo, evidenziando come la similarità coseno sia particolarmente adatta per il text mining e per tutti i problemi in cui gli oggetti sono rappresentati da vettori ad alta dimensionalità basati su frequenze.

La similarità coseno è anche una distanza. Vero o falso? Giustificare la risposta.

Risposta:

Falso.

La similarità coseno non è una distanza perché non soddisfa le proprietà richieste da una metrica di distanza. In particolare, una distanza deve essere nulla quando gli oggetti coincidono e aumentare al crescere della loro dissimilarità. La similarità coseno invece assume valore massimo pari a uno quando i vettori sono identici e valore minimo pari a zero quando sono ortogonali, cioè completamente diversi.

Inoltre, non rappresenta direttamente una misura di “quanto distano” due oggetti, ma piuttosto quanto sono allineati tra loro nello spazio. Nelle slide viene esplicitamente sottolineato che la similarità coseno non è una distanza, proprio per evitare questo errore concettuale molto comune.

Che tipo di apprendimento si utilizza quando si creano modelli per il clustering?

Risposta corretta:
👉 Non supervisionato

Gli algoritmi di clustering si utilizzano per generare:

Risposta corretta:
👉 Modelli descrittivi

Quale affermazione è falsa?

Risposta corretta:
👉 *E' sempre noto a priori il numero di cluster da cercare*

✔️ Spesso **NON è noto**, ed è proprio una delle difficoltà principali del clustering.

Un algoritmo di clustering produce cluster di alta qualità se assicura:

Risposta corretta:
👉 Alta similarità intra-cluster e bassa similarità inter-cluster

📌 Confermato dalle slide (pagina 2):

- alta similarità interna
- bassa similarità tra cluster

Differenza tra clustering e classificazione

Risposta:

La principale differenza tra clustering e classificazione riguarda la presenza o meno di etichette nei dati.

Nella classificazione si lavora in un contesto supervisionato, dove ogni istanza è associata a una classe nota e l'obiettivo è costruire un modello in grado di assegnare nuove istanze a una delle classi predefinite.

Nel clustering invece non esistono classi predefinite e i dati non sono etichettati. L'obiettivo è scoprire automaticamente gruppi naturali nei dati, basandosi sulla similarità tra le istanze.

In sintesi, la classificazione predice etichette note, mentre il clustering scopre strutture nascoste nei dati.

Requisiti degli algoritmi di clustering

Risposta:

Gli algoritmi di clustering devono soddisfare diversi requisiti fondamentali per essere efficaci:

- **Scalabilità**, cioè la capacità di gestire grandi quantità di dati e molti attributi
- **Gestione di attributi diversi**, inclusi dati numerici, categorici e misti
- **Clustering con vincoli**, ovvero la possibilità di incorporare conoscenza del dominio
- **Interpretabilità e usabilità**, i risultati devono essere comprensibili e utilizzabili

Inoltre devono affrontare alcune sfide come:

- gestione del rumore
- identificazione di cluster di forma arbitraria
- gestione di dati ad alta dimensionalità

📌 Tutti questi punti sono nelle slide (pagina 8-9)

Definizione di cluster

Risposta:

Un cluster è un insieme di oggetti che sono tra loro simili e dissimili rispetto agli oggetti appartenenti ad altri gruppi.

Formalmente, un cluster è un gruppo in cui:

- la distanza tra gli elementi interni è minima (alta similarità intra-cluster)
- la distanza rispetto agli altri cluster è massima (bassa similarità inter-cluster)

Differenza tra apprendimento supervisionato e non supervisionato

Risposta:

La differenza principale tra apprendimento supervisionato e non supervisionato riguarda la disponibilità delle etichette nei dati.

Nel **supervisionato**, il modello viene addestrato su dati etichettati, cioè per ogni istanza è nota la risposta corretta. L'obiettivo è imparare una funzione che permetta di fare previsioni su nuovi dati.

Nel **non supervisionato**, invece, i dati non sono etichettati e il modello deve individuare autonomamente strutture, pattern o gruppi nascosti nei dati.

Il clustering è un esempio tipico di apprendimento non supervisionato, mentre la classificazione è un esempio di apprendimento supervisionato.

Perfetto, qui saliamo di livello 💥
Questa lezione è **molto da esame teorico**, quindi ti preparo risposte pulite + spiegazione vera (così capisci, non memorizzi a caso).

SOM (Self Organizing Map) appartiene a:

Risposta corretta:
👉 Nessuna delle altre alternative

✔️ Perché è un algoritmo **model-based (rete neurale)**

Algoritmi migliori per identificare outlier

Risposta corretta:
👉 Density-based

✔️ Perché:

- individuano rumore
- trovano outlier naturalmente

AGNES appartiene a:

Risposta corretta:
👉 Gerarchici

✔️ AGNES = **Agglomerative** → gerarchico

K-means appartiene a:

Risposta corretta:
👉 Partizionali

✔️ Divide i dati in k gruppi fissati

Caratteristiche algoritmi density-based

Risposta:

Gli algoritmi density-based identificano i cluster basandosi sulla densità dei dati nello spazio. Un cluster è definito come una regione in cui la densità dei punti supera una certa soglia.

Il funzionamento si basa sul concetto di vicinato: per ogni punto, si considera un'area (definita da un raggio) e si verifica se contiene un numero minimo di punti.

Le principali caratteristiche sono:

- capacità di individuare cluster di forma arbitraria
- robustezza al rumore
- identificazione naturale degli outlier
- non necessitano di specificare a priori il numero di cluster

📌 Dalle slide (pagina 5):

- crescita del cluster finché la densità supera una soglia
- individuazione di rumore e outlier

Come funzionano gli algoritmi gerarchici

Risposta:

Gli algoritmi gerarchici costruiscono una struttura ad albero (gerarchia) dei cluster.

Esistono due approcci:

- **Agglomerativo (bottom-up):**
  ogni oggetto parte come cluster singolo e i cluster più simili vengono progressivamente uniti fino a ottenere un unico cluster o soddisfare una condizione di stop
- **Divisivo (top-down):**
  si parte da un unico cluster contenente tutti i dati e lo si divide progressivamente in cluster più piccoli

Una caratteristica importante è che le operazioni di unione o divisione **non sono reversibili**, il che può portare a errori irreversibili nel clustering

Tassonomia algoritmi di clustering

Risposta:

Gli algoritmi di clustering possono essere classificati (tassonomia) in base alle loro caratteristiche principali.

Le principali categorie sono:

- **Algoritmi partizionali** → dividono i dati in k cluster (es. k-means)
- **Algoritmi gerarchici** → creano una struttura ad albero di cluster
- **Algoritmi density-based** → basati sulla densità dei dati
- **Algoritmi su griglia** → suddividono lo spazio in celle
- **Algoritmi model-based** → assumono un modello probabilistico o neurale

📌 Dalle slide (pagina 5): elenco completo delle categorie

Differenza tra partizionali e density-based

Risposta:

La principale differenza riguarda il criterio con cui vengono costruiti i cluster.

Gli algoritmi **partizionali**:

- dividono i dati in k gruppi
- sono basati sulla distanza
- richiedono il numero di cluster a priori
- tendono a trovare cluster di forma sferica

Gli algoritmi **density-based**:

- identificano cluster come regioni ad alta densità
- non richiedono il numero di cluster a priori
- individuano cluster di forma arbitraria
- sono robusti al rumore e agli outlier

📌 Dalle slide:

- partizionali → basati su distanza
- density → basati su densità e rilevano outlier

Quale fra i seguenti criteri non rappresenta un criterio di convergenza dell'algoritmo di clustering k-means?

Risposta corretta:
Riduzione eccessiva delle partizioni iniziali

Quali sono i punti di forza dell'algoritmo di clustering K-means?

Risposta corretta:

1. Efficienza, in quanto è lineare rispetto al numero di oggetti, 2) Termina in un ottimo locale

Quali sono i principali parametri che occorre fissare per effettuare il clustering tramite l'algoritmo K-means?

Risposta corretta:
Il numero K di cluster e il criterio di stop

Quale è la differenza fra cluster e centroide nell'algoritmo di clustering K-means?

Risposta:

Nel contesto dell'algoritmo K-means, un cluster rappresenta un insieme di punti che risultano tra loro simili secondo una determinata misura di distanza, mentre il centroide è il punto che rappresenta sinteticamente quel gruppo. Il centroide viene calcolato come la media dei punti appartenenti al cluster e ha il ruolo di rappresentare la posizione centrale del gruppo nello spazio delle caratteristiche. Durante l'esecuzione dell'algoritmo, i punti vengono assegnati al cluster il cui centroide è più vicino, e successivamente i centroidi vengono aggiornati sulla base delle nuove assegnazioni. In questo modo il centroide guida la formazione del cluster, mentre il cluster è l'insieme effettivo dei punti associati a quel centroide.

Discutere l'idea di base nell'algoritmo di clustering K-means?

Risposta:

L'algoritmo K-means è un metodo di clustering di tipo iterativo che ha l'obiettivo di suddividere un insieme di dati in un numero prefissato di gruppi, in modo tale che gli elementi appartenenti allo stesso gruppo siano il più possibile simili tra loro. Il funzionamento si basa su un processo che alterna due fasi principali: inizialmente vengono scelti dei punti rappresentativi, chiamati centroidi, e successivamente ogni elemento del dataset viene assegnato al centroide più vicino secondo una misura di distanza. Una volta effettuata questa assegnazione, i centroidi vengono ricalcolati come media dei punti che appartengono a ciascun cluster. Questo processo viene ripetuto fino a quando le assegnazioni non cambiano più o la funzione obiettivo non varia in modo significativo, portando così a una suddivisione stabile dei dati.

Scrivere in pseudo codice o in un linguaggio di programmazione conosciuto l'algoritmo di clustering K-means?

Risposta:

L’algoritmo K-means può essere descritto attraverso una sequenza di passi che vengono ripetuti fino al raggiungimento della convergenza. Si parte inizializzando K centroidi, scelti generalmente in modo casuale tra i punti del dataset. Successivamente, per ogni punto si calcola la distanza rispetto a ciascun centroide e lo si assegna al cluster il cui centroide è più vicino. Dopo aver assegnato tutti i punti, si ricalcolano i centroidi come media dei punti appartenenti a ciascun cluster. Questo processo di assegnazione e aggiornamento viene ripetuto iterativamente fino a quando non si verifica una condizione di arresto, come l’assenza di cambiamenti nelle assegnazioni o una variazione minima della funzione obiettivo.

Quale è la misura che si ottimizza nell'algoritmo di clustering K-means?

Risposta:

Nell’algoritmo K-means viene ottimizzata una funzione obiettivo che misura la compattezza dei cluster, ovvero la somma delle distanze quadratiche tra ogni punto e il centroide del cluster a cui appartiene. L’obiettivo dell’algoritmo è minimizzare questa quantità, in modo da ottenere cluster in cui i punti siano il più possibile vicini al proprio centroide. In questo modo si riduce la variabilità interna ai cluster e si ottiene una suddivisione dei dati più coerente. Le slide evidenziano che questa funzione rappresenta la varianza intra-cluster e costituisce il criterio principale su cui si basa l’intero algoritmo.

L'algoritmo gerarchico di clustering DIANA quale approccio segue?

Risposta corretta:
Divisivo

L'algoritmo gerarchico di clustering AGNES quale approccio segue?

Risposta corretta:
Agglomerativo

Che cosa è un dendogramma?

Risposta corretta:
E' un diagramma ad albero che mostra le sequenza di fusioni fra cluster generati man mano da un algoritmo di clustering gerarchico

Negli algoritmi di clustering gerarchici con approccio agglomerativo come avviene l'inizializzazione?

Risposta corretta:
Si parte con tanti cluster quanti sono gli oggetti

Discutere i passi principali dell'algoritmo DIANA.

Risposta:

L'algoritmo DIANA segue un approccio divisivo e lavora in maniera opposta rispetto agli algoritmi agglomerativi. Inizialmente tutti gli oggetti vengono inseriti in un unico cluster. Successivamente, ad ogni iterazione viene selezionato il cluster con il diametro massimo, cioè quello con la maggiore dissimilarità interna. All'interno di questo cluster viene individuato l'oggetto che ha la massima distanza media rispetto agli altri e questo diventa il primo elemento di un nuovo cluster. Gli altri oggetti vengono progressivamente assegnati al nuovo cluster se risultano più vicini ad esso rispetto al cluster originale. Il processo continua finché non si ottiene una suddivisione completa o si raggiunge una condizione di arresto.

Discutere lo schema base di un un algoritmo di clustering gerarchico agglomerativo.

Risposta:

Un algoritmo gerarchico agglomerativo segue un approccio bottom-up. Si parte inizialmente considerando ogni oggetto come un cluster singolo. Ad ogni iterazione vengono individuati i due cluster più simili secondo una misura di distanza e vengono fusi in un unico cluster. Dopo ogni fusione viene aggiornata la matrice delle distanze tra cluster. Questo processo continua iterativamente fino a ottenere un unico cluster contenente tutti gli oggetti oppure fino a soddisfare un criterio di arresto. L'intero processo può essere rappresentato tramite un dendrogramma che mostra le fusioni successive tra cluster.

Come si calcola la distanza fra due cluster nati dalla fusione di due o più cluster?

Risposta:

La distanza tra due cluster può essere calcolata utilizzando diversi criteri, detti metodi di linkage. Tra i più comuni vi è il single link, che considera la distanza minima tra una coppia di elementi appartenenti ai due cluster. Altri metodi includono il complete link, che utilizza la

distanza massima, e l’average link, che considera la distanza media tra tutti gli elementi dei cluster. La scelta del metodo influenza la forma e la struttura dei cluster ottenuti.

Che cosa è il dendogramma?

Risposta:

Il dendrogramma è una rappresentazione grafica ad albero che descrive il processo di clustering gerarchico. Esso mostra come i cluster vengono progressivamente uniti (nel caso agglomerativo) o divisi (nel caso divisivo) e a quale livello di distanza avvengono queste operazioni. L’altezza dei nodi nel dendrogramma rappresenta il grado di dissimilarità tra i cluster che vengono uniti, permettendo così di individuare visivamente una possibile suddivisione dei dati.

Quali sono i pro e contro degli algoritmi di clustering gerarchico?

Risposta:

Gli algoritmi di clustering gerarchico presentano il vantaggio di non richiedere a priori il numero di cluster, poiché questo può essere determinato successivamente analizzando il dendrogramma. Inoltre, forniscono una rappresentazione completa della struttura dei dati e permettono di osservare le relazioni tra cluster a diversi livelli di granularità. Tuttavia, presentano anche alcuni svantaggi, tra cui un’elevata complessità computazionale che li rende poco adatti a dataset molto grandi e la sensibilità al rumore e agli outlier. Inoltre, una volta effettuata una fusione o una divisione, questa non può essere annullata.

Quale è la principale differenza fra gli algoritmi AGNES e DIANA?

Risposta:

La principale differenza tra AGNES e DIANA riguarda l’approccio utilizzato nella costruzione dei cluster. AGNES segue un approccio agglomerativo, partendo da singoli elementi e unendo progressivamente i cluster fino a formarne uno unico. DIANA, invece, adotta un approccio divisivo, iniziando da un unico cluster contenente tutti gli oggetti e suddividendolo progressivamente in cluster più piccoli. In sostanza, AGNES costruisce la gerarchia dal basso verso l’alto, mentre DIANA la costruisce dall’alto verso il basso.

Quali sono i principali parametri che occorre fissare per effettuare il clustering tramite l'algoritmo DBSCAN?

Risposta corretta:
Nessuna delle altre alternative

Oltre al valore del massimo raggio del vicinato, quale altro parametro deve essere specificato per l'algoritmo di clustering DBSCAN?

Risposta corretta:
Il minimo numero di punti che devono essere contenuti all'interno di un vicinato

Quando si parla di algoritmo di clustering DBSCAN, cosa sono i core point?

Risposta corretta:
Sono i punti la cui densità (numero di punti) è superiore a MinPts

Cosa rappresenta il parametro Epsilon dell'algoritmo di clustering DBSCAN?

Risposta corretta:
Il massimo raggio del vicinato

Discutere i pro e i contro dell'algoritmo di clustering DBSCAN.

Risposta:

L'algoritmo DBSCAN presenta diversi vantaggi che lo rendono molto efficace in molti contesti applicativi. Innanzitutto non richiede di specificare a priori il numero di cluster, a differenza di altri algoritmi come il K-means. Inoltre è in grado di individuare cluster di forma arbitraria e non necessariamente sferica, ed è particolarmente robusto al rumore, riuscendo a identificare in modo naturale gli outlier. Tuttavia presenta anche alcune limitazioni. La scelta dei parametri, in particolare del raggio ε e del valore MinPts, è critica e può influenzare significativamente il risultato. Inoltre l'algoritmo può avere difficoltà quando i dati presentano densità molto diverse tra loro o quando si lavora in spazi ad alta dimensionalità.

Mostrare una implementazione del DBSCAN usando uno pseudocodice o un linguaggio di programmazione.

Risposta:

L'algoritmo DBSCAN può essere descritto attraverso un processo iterativo in cui si visitano tutti i punti del dataset. Per ogni punto non ancora visitato si calcola il suo vicinato, cioè l'insieme dei punti che si trovano a distanza minore o uguale a ε. Se il numero di punti nel vicinato è inferiore a MinPts, il punto viene etichettato come rumore. Altrimenti viene creato

un nuovo cluster e si procede ad espanderlo includendo tutti i punti direttamente raggiungibili. Questo processo continua in modo ricorsivo, considerando anche i vicinati dei nuovi punti aggiunti, finché non è più possibile espandere ulteriormente il cluster. L'algoritmo termina quando tutti i punti sono stati visitati e assegnati a un cluster oppure classificati come rumore.

Discutere l'idea di base dell'algoritmo di clustering DBSCAN

Risposta:

L'idea di base dell'algoritmo DBSCAN è quella di identificare i cluster come regioni dello spazio in cui i dati sono distribuiti con una certa densità. In particolare, un cluster è formato da un insieme di punti che sono densamente connessi tra loro, mentre le regioni a bassa densità vengono considerate come rumore. L'algoritmo parte da un punto e verifica se il numero di punti nel suo vicinato supera una soglia minima. Se ciò accade, il punto viene considerato un punto centrale e viene utilizzato per espandere il cluster includendo tutti i punti raggiungibili. Questo processo permette di costruire cluster anche molto complessi, senza fare ipotesi sulla loro forma.

Definire e mostrare graficamente cosa sono i Core point, Border Point e Noise Point nel contesto dell'algoritmo DBSCAN.

Risposta:

Nel contesto dell'algoritmo DBSCAN, i punti del dataset vengono classificati in base alla densità del loro vicinato. Un core point è un punto che ha almeno MinPts punti nel suo intorno definito dal raggio ε e rappresenta il nucleo di un cluster. Un border point è un punto che non soddisfa la condizione per essere un core point, ma si trova comunque nel vicinato di un core point e quindi appartiene al cluster. Un noise point, infine, è un punto che non è né core né border, perché non ha abbastanza vicini e non è collegato a nessun cluster, e viene quindi considerato un outlier.

Che cosa è il supporto di una regola associativa?

Risposta corretta:
E' la frequenza relativa delle transazioni nel database che verificano la regola

Che cosa è la confidenza di una regola associativa?

Risposta corretta:
E' la frequenza delle transazioni nel database che verificano la regola rispetto a quelle che ne verificano l'antecedente

Quando una regola associativa si definisce forte?

Risposta corretta:
Si definisce forte, una regola associativa che soddisfa un supporto minimo prefissato ed una confidenza minima prefissata

La generazione di regole associative avviene utilizzando che tipologia di apprendimento?

Risposta corretta:
Non supervisionato

Che cosa è una regola associativa?

Risposta corretta:
E' è un'implicazione della forma X->Y, dove X e Y sono degli itemset

Cosa è la Market Basket Analysis?

Risposta corretta:
Una analisi ha l'obiettivo di studiare la regolarità, all'interno delle transazioni registrate, nelle vendite dei supermercati

Che cosa è un itemset?

Risposta corretta:
Un insieme di articoli

Quando una regola associativa si dice forte?

Risposta:

Una regola associativa si dice forte quando soddisfa contemporaneamente due condizioni fondamentali, cioè un valore minimo di supporto e un valore minimo di confidenza stabiliti a priori. Questo significa che la regola non solo compare con una certa frequenza all'interno del database, ma è anche sufficientemente affidabile nel descrivere la relazione tra antecedente e conseguente. In altre parole, una regola è considerata significativa quando è sia abbastanza diffusa nei dati sia sufficientemente precisa nel rappresentare una relazione tra gli item.

Quale è la differenza fra supporto di un itemset e supporto di una regola associativa?

Risposta:

Il supporto di un itemset rappresenta il numero o la frequenza di transazioni che contengono quell'insieme di elementi all'interno del database. Il supporto di una regola associativa, invece, misura la frequenza con cui si verifica contemporaneamente sia l'antecedente che il conseguente della regola, quindi si riferisce all'unione dei due itemset. In sostanza, mentre il supporto di un itemset riguarda solo la presenza di determinati elementi, il supporto di una regola valuta quanto spesso quella specifica relazione tra due insiemi di elementi si manifesta nei dati.

Cosa è una regola associativa?

Risposta:

Una regola associativa è una relazione espressa sotto forma di implicazione tra due insiemi di elementi, indicata generalmente come $X \Rightarrow Y$, dove X rappresenta l'antecedente e Y il conseguente. Questa regola indica che quando nelle transazioni compare l'insieme X, è probabile che compaia anche l'insieme Y. Le regole associative vengono utilizzate per individuare pattern ricorrenti nei dati e sono alla base di molte analisi, come ad esempio lo studio dei comportamenti di acquisto dei clienti.

Definire i concetti di Item, itemset e transazioni.

Risposta:

Un item rappresenta un singolo elemento o articolo, come ad esempio un prodotto acquistato in un supermercato. Un itemset è invece un insieme di item, cioè una combinazione di più elementi considerati insieme. Una transazione rappresenta un'unità di osservazione del database e contiene un insieme di item acquistati o osservati contemporaneamente. In pratica, una transazione può essere vista come un carrello della spesa, mentre gli item sono i prodotti e l'itemset è il gruppo di prodotti presenti in quella specifica transazione.

A cosa serve l'algoritmo APRIORI?

Risposta corretta:
Per generare regole associative

Quale è l'idea di base dell'algoritmo APRIORI?

Risposta corretta:
L'algoritmo Apriori affronta la fase di generazione degli itemset frequenti per approssimazioni successive, a partire dagli itemset con un solo elemento

Che cosa è un itemset frequente?

Risposta corretta:
Un itemset con supporto maggiore di un valore stabilito

Per la generazione di regole associative, in genere è necessario generare come prima cosa:

Risposta corretta:
Gli itemset frequenti

Su quali basi teoriche si fonda l'algoritmo Apriori?

Risposta:

L'algoritmo Apriori si fonda sul cosiddetto principio Apriori, secondo il quale ogni sottoinsieme di un itemset frequente è anch'esso frequente. Questo implica una proprietà di antimonotonicità del supporto, cioè il supporto di un insieme non può essere maggiore di quello dei suoi sottoinsiemi. Grazie a questo principio è possibile ridurre drasticamente lo spazio di ricerca, eliminando a priori tutti i candidati che contengono sottoinsiemi non frequenti.

Cosa si intende per association rule mining?

Risposta:

L'association rule mining è il processo di estrazione automatica di regole associative da un insieme di dati, con l'obiettivo di individuare relazioni significative tra gruppi di elementi all'interno delle transazioni. Questo processo consente di scoprire pattern ricorrenti, come ad esempio prodotti acquistati insieme, ed è alla base di tecniche come la Market Basket Analysis.

Discutere brevemente i passi dell'algoritmo Apriori per la generazione di itemset frequenti.

Risposta:

L'algoritmo Apriori inizia calcolando il supporto di tutti gli item singoli e scartando quelli che non soddisfano la soglia minima. Successivamente genera iterativamente insiemi di item sempre più grandi a partire da quelli frequenti del passo precedente. Per ogni insieme candidato viene calcolato il supporto e vengono eliminati quelli che non raggiungono il valore minimo. Questo processo continua aumentando progressivamente la dimensione degli itemset finché non è più possibile generare nuovi insiemi frequenti.

Quali sono i parametri più importanti da fissare per l'algoritmo APRIORI?

Risposta corretta:
Valore del supporto minimo, valore della confidenza minima

Che approccio usa APRIORI per la generazione di regole associative?

Risposta corretta:
L'algoritmo Apriori usa un approccio per livelli per generare le regole associative.
Ogni livello corrisponde al numero di item che appartengono al conseguente.

E' possibile aumentare l'efficienza dell'algoritmo APRIORI?

Risposta corretta:
Si, ma solo riducendo il numero di candidati da considerare, usando tecniche di indirizzamento e partizionamento

Mostrare un esempio di traliccio delle regole associative contenente regole potate.

Risposta:

Un esempio di traliccio delle regole associative può essere costruito partendo da un itemset frequente come {A, B, C, D}. Da questo insieme si generano tutte le possibili regole, considerando tutte le combinazioni tra antecedente e conseguente. Tuttavia, durante la verifica della confidenza, alcune regole risultano non soddisfare la soglia minima stabilita. In questi casi, tali regole vengono eliminate e, di conseguenza, anche tutte le regole che da esse derivano vengono scartate. Il traliccio rappresenta quindi tutte le possibili regole, mentre le regole potate sono quelle rimosse perché non sufficientemente affidabili.

Cosa è la proprietà di antimonotinicità? Vale per il supporto, per la confidenza o per entrambi?

Risposta:

La proprietà di antimonotonicità afferma che se un itemset è frequente, allora anche tutti i suoi sottoinsiemi devono essere frequenti. Questo significa che il supporto di un insieme non può essere maggiore di quello dei suoi sottoinsiemi. Tale proprietà è fondamentale per ridurre lo spazio di ricerca nell’algoritmo Apriori, perché consente di eliminare in anticipo molti candidati non validi. Questa proprietà vale esclusivamente per il supporto e non per la confidenza, che invece non segue questo comportamento e deve essere calcolata esplicitamente per ogni regola.

Riportare e discutere lo pseudocodice dell'algoritmo Apriori per la generazione di regole associative forti (si consideri di avere già gli itemset frequenti).

Risposta:

L’algoritmo Apriori per la generazione delle regole associative forti parte dagli itemset frequenti già calcolati. Per ciascun itemset frequente con almeno due elementi, vengono inizialmente considerati tutti i possibili conseguenti costituiti da un solo elemento. Per ogni possibile regola si calcola la confidenza confrontando il supporto dell’intero itemset con quello dell’antecedente. Se la confidenza soddisfa la soglia minima, la regola viene accettata; altrimenti viene eliminata. Successivamente, l’algoritmo genera conseguenti di dimensione maggiore combinando quelli già validi e ripete il processo in modo iterativo, fermandosi quando non è più possibile generare nuove regole valide. Questo approccio consente di costruire le regole in modo progressivo e di eliminare quelle non significative senza dover analizzare nuovamente il database.

Come si può migliorare l'efficienza dell'algoritmo Apriori?

Risposta:

L’efficienza dell’algoritmo Apriori può essere migliorata principalmente riducendo il numero di candidati da generare e da valutare durante l’esecuzione. Questo è possibile sfruttando la proprietà di antimonotonicità del supporto per eliminare in anticipo gli itemset non promettenti. Inoltre, si possono utilizzare tecniche come il partizionamento del database, che consente di lavorare su sottoinsiemi dei dati, oppure strategie di hashing e strutture dati efficienti per velocizzare il conteggio del supporto. L’obiettivo è limitare il numero di scansioni del database e ridurre il costo computazionale complessivo.

Quale è l'idea di base per la generazione di regole associative forti in Apriori?

Risposta:

L’idea di base consiste nel partire dagli itemset frequenti e generare tutte le possibili regole associative combinando i loro sottoinsiemi. Per ciascuna regola si verifica la confidenza, mantenendo solo quelle che superano la soglia minima stabilita. Il supporto non deve essere ricalcolato perché è già garantito dal fatto che l’itemset di partenza è frequente. Il processo avviene in modo progressivo, partendo da regole semplici con conseguente di dimensione uno e ampliandole solo se risultano valide, evitando così di considerare combinazioni inutili.

Con riferimento all'algoritmo FP-growth, quante scansioni del data base vengono effettuate per la generazione dell'FP-tree?

Risposta corretta:
Due

L'algoritmo FP-growth consente di evitare cosa?

Risposta corretta:
La generazione degli itemset frequenti candidati

Con riferimento all'algoritmo FP-growth, cosa viene fatto durante la seconda scansione nella fase di generazione dell'FP-tree?

Risposta corretta:
Si crea effettivamente l'albero

Con riferimento all'algoritmo FP-growth, cosa viene fatto nei primi due passi della generazione dell'FP-tree?

Risposta corretta:
1), Si identificano tutti gli 1-temset frequenti dal database, 2) Si crea una lista L degli 1-itemset frequenti ordinati secondo il loro supporto o frequenza

A cosa serve l'FP-tree?

Risposta corretta:
A comprimere il database considerando solo gli item frequenti

Quale è l'idea di base di FP-growth?

Risposta:

L’idea di base dell’algoritmo FP-growth consiste nel trovare gli itemset frequenti senza generare esplicitamente i candidati, come invece avviene nell’algoritmo Apriori. Questo risultato viene ottenuto comprimendo il database in una struttura ad albero chiamata FP-tree, che conserva le informazioni essenziali sugli item frequenti. Una volta costruito l’albero, l’algoritmo estrae gli itemset frequenti attraverso un processo di esplorazione ricorsiva, sfruttando le relazioni tra i nodi dell’albero e riducendo così il numero di operazioni necessarie.

Quali sono i due passi principali dell'algoritmo FP-growth?

Risposta:

L'algoritmo FP-growth si articola in due fasi principali. Nella prima fase viene costruito l'FP-tree, che rappresenta una versione compressa del database contenente solo gli item frequenti e organizzata in modo da evidenziare le loro co-occorrenze. Nella seconda fase, l'algoritmo utilizza l'FP-tree per estrarre gli itemset frequenti attraverso una procedura ricorsiva che costruisce alberi condizionati e individua progressivamente i pattern frequenti senza dover riesaminare l'intero database.

Discutere le principali differenze fra Apriori ed FP-growth

Risposta:

La principale differenza tra Apriori e FP-growth riguarda il modo in cui vengono generati gli itemset frequenti. L'algoritmo Apriori utilizza un approccio basato sulla generazione e verifica di candidati, che comporta numerose scansioni del database e un elevato costo computazionale. FP-growth, invece, evita completamente la generazione esplicita dei candidati e si basa su una struttura compatta, l'FP-tree, che permette di rappresentare il database in modo compresso. Inoltre, mentre Apriori richiede molteplici passaggi sul database, FP-growth necessita di sole due scansioni, risultando generalmente più efficiente soprattutto su dataset di grandi dimensioni.

Che cosa è un FP-tree e come si crea?

Risposta:

L'FP-tree è una struttura ad albero utilizzata per rappresentare in forma compatta il database delle transazioni, mantenendo solo le informazioni relative agli item frequenti. La sua costruzione avviene in due passaggi: inizialmente si effettua una scansione del database per individuare gli item frequenti e ordinarli in base al supporto. Successivamente, durante una seconda scansione, le transazioni vengono inserite nell'albero seguendo questo ordine, condividendo i prefissi comuni tra i percorsi e incrementando i contatori dei nodi. In questo modo si ottiene una rappresentazione compressa che facilita l'estrazione degli itemset frequenti.

Cosa sono e a cosa servono la header table e i node-links

Risposta:

La header table è una struttura che contiene l’elenco degli item frequenti ordinati per supporto e mantiene un collegamento ai nodi corrispondenti presenti nell’FP-tree. I node-links sono invece collegamenti tra nodi dell’albero che rappresentano lo stesso item e permettono di attraversare rapidamente tutte le occorrenze di quell’item all’interno dell’albero. Queste strutture sono fondamentali perché consentono di esplorare l’FP-tree in modo efficiente durante la fase di estrazione degli itemset frequenti, evitando di dover analizzare nuovamente l’intero albero.

Con riferimento all'algoritmo FP-growth, che filosofia si utilizza per la generazione degli itemset frequenti?

Risposta corretta:
Si segue un approccio bottom-up: si parte ad esplorare l'albero dei pattern frequenti a partire dalle foglie verso la radice

Quale potrebbe essere uno svantaggio dell'algoritmo FP-growth?

Risposta corretta:
L'FP-tree potrebbe essere computazionalmente difficile da generare

Quale potrebbe essere uno svantaggio dell'algoritmo FP-growth?

Risposta corretta:
L'FP-tree potrebbe non entrare in memoria

In quale fase dell'algoritmo FP-growth si genera il conditional pattern tree?

Risposta corretta:
Nella fase di estrazione degli itemset frequenti

Come si genera un conditional FP-tree?

Risposta:

Il conditional FP-tree viene generato a partire dal conditional pattern base associato a un determinato item. Si individuano innanzitutto tutti i percorsi dell’FP-tree che terminano con quell’item, raccogliendo così le informazioni sulle transazioni che lo contengono. Questi percorsi vengono poi utilizzati per costruire una base condizionata, nella quale si considerano solo gli item frequenti rispetto a quel contesto specifico. Infine, da questa base

viene costruito un nuovo FP-tree ridotto, chiamato conditional FP-tree, che rappresenta le co-occorrenze degli item rispetto all'item considerato.

In che punto dell'algoritmo FP-growth è presente la parte ricorsiva?

Risposta:

La parte ricorsiva dell'algoritmo FP-growth si trova nella fase di estrazione degli itemset frequenti. Dopo aver costruito l'FP-tree iniziale, l'algoritmo analizza ogni item della header table e genera per ciascuno il relativo conditional FP-tree. Questo processo viene poi applicato nuovamente su ogni albero condizionato, ripetendo la procedura fino a quando non è più possibile generare nuovi pattern. In questo modo l'algoritmo esplora ricorsivamente tutte le possibili combinazioni di item frequenti.

Discutere la differenza fra: suffix pattern base, conditional pattern base e conditional FP-tree.

Risposta:

Il suffix pattern base rappresenta l'insieme dei pattern che terminano con un determinato item ed è il punto di partenza per l'analisi condizionata. A partire da questo insieme si costruisce il conditional pattern base, che consiste nei percorsi dell'FP-tree che portano a quell'item, opportunamente pesati in base alla loro frequenza. Il conditional FP-tree è invece la struttura ad albero costruita a partire dal conditional pattern base, che rappresenta una versione ridotta del problema originale e permette di individuare nuovi itemset frequenti legati a quell'item.

Come si costruisce un conditional pattern base?

Risposta:

Il conditional pattern base viene costruito esaminando tutti i percorsi dell'FP-tree che terminano con un determinato item. Per ciascun nodo corrispondente a quell'item si risale il percorso fino alla radice, raccogliendo gli item incontrati lungo il cammino. Questi percorsi vengono memorizzati insieme alla loro frequenza e costituiscono la base condizionata, che rappresenta tutte le transazioni rilevanti per l'item considerato.

Come si identificano i pattern frequenti nell'algoritmo FP-growth?

Risposta:

I pattern frequenti vengono identificati esplorando l'FP-tree e i suoi alberi condizionati. L'algoritmo analizza ogni item della header table e costruisce il relativo conditional FP-tree,

che rappresenta il contesto in cui quell'item compare. Attraverso un processo ricorsivo, vengono combinati gli item per formare pattern sempre più grandi, mantenendo solo quelli che soddisfano la soglia minima di supporto. In questo modo si ottengono tutti gli itemset frequenti senza dover generare esplicitamente candidati.

Quali sono i principali vantaggi e svantaggi dell'FP-growth?

Risposta:

L'algoritmo FP-growth presenta come principale vantaggio l'elevata efficienza, dovuta al fatto che evita la generazione esplicita dei candidati e richiede solo due scansioni del database. Inoltre, grazie alla struttura compatta dell'FP-tree, riesce a gestire in modo efficace dataset anche di grandi dimensioni. Tuttavia, presenta anche alcuni svantaggi, tra cui la complessità nella costruzione dell'albero e il fatto che, in presenza di dati molto grandi o con poche condivisioni tra transazioni, l'FP-tree può diventare troppo grande e difficile da gestire in memoria.

Cosa si intende per classificazione binaria?

Risposta corretta:
Si considerano solo due classi

A che categoria di classificatori appartiene il KNN?

Risposta corretta:
Lazy

Che tipo di apprendimento si utilizza quando si creano modelli di classificazione?

Risposta corretta:
Supervisionato

Come sono i dataset che in genere si utilizzano nel contesto della classificazione?

Risposta corretta:
Etichettati

Esistono differenze fra problemi di clustering e di classificazione?

Risposta corretta:
Si

Discutere la differenza fra classificazione binaria e classificazione multi-classe.

Risposta:

La classificazione binaria è un tipo di problema in cui l'obiettivo è assegnare ogni istanza a una delle due possibili classi, come ad esempio positivo o negativo. Questo tipo di classificazione è generalmente più semplice perché il modello deve distinguere tra due sole alternative. La classificazione multi-classe, invece, prevede la presenza di più di due classi e richiede al modello di assegnare ogni istanza a una tra diverse possibili categorie. Questo rende il problema più complesso, perché aumenta il numero di decisioni possibili e spesso richiede strategie aggiuntive per gestire correttamente la separazione tra le classi.

Discutere le principali differenze fra classificazione e clustering.

Risposta:

La classificazione è un problema di apprendimento supervisionato in cui si dispone di dati etichettati e l'obiettivo è costruire un modello in grado di assegnare nuove istanze a una delle classi già note. Il clustering, invece, è un problema di apprendimento non supervisionato, in cui non sono disponibili etichette e l'obiettivo è individuare automaticamente gruppi di dati simili tra loro. In sostanza, la classificazione utilizza conoscenza preesistente per fare previsioni, mentre il clustering cerca di scoprire strutture nascoste nei dati senza informazioni preliminari.

Cosa sono i multi-classificatori?

Risposta:

I multi-classificatori sono modelli di classificazione progettati per gestire problemi in cui sono presenti più di due classi. Possono essere costruiti direttamente per supportare più classi oppure ottenuti combinando più classificatori binari, ad esempio utilizzando strategie come one-vs-all o one-vs-one. L'obiettivo è quello di estendere le tecniche di classificazione binaria a contesti più complessi in cui le categorie possibili sono numerose.

Riassumere brevemente le fasi del processo di classificazione.

Risposta:

Il processo di classificazione inizia con la preparazione dei dati, che include la raccolta e il preprocessing del dataset. Successivamente si procede con la fase di addestramento, durante la quale il modello impara a partire dai dati etichettati. Una volta costruito il modello, questo viene valutato utilizzando dati di test per verificarne le prestazioni. Infine, il modello viene utilizzato per classificare nuove istanze, assegnando loro una classe sulla base delle informazioni apprese durante l'addestramento.

Su cosa si base il calcolo dell'information gain?

Risposta corretta:
Sull'entropia

Che tipo di problema risolvono gli alberi di decisione?

Risposta corretta:
Classificazione

Cosa rappresenta ogni nodo interno in un albero di decisione?

Risposta corretta:
Un attributo

Cosa rappresenta una foglia in un albero di decisione?

Risposta corretta:
Il valore predetto per la classe

Con riferimento agli alberi di decisione, che filosofia si utilizza per la generazione della classe stimata?

Risposta corretta:
Si segue un approccio top-down: si parte ad esplorare l'albero dalla radice verso le foglie

Nella generazione degli alberi di decisione, l'information gain in genere viene usato come misura di cosa?

Risposta corretta:
Misura di rilevanza

Discutere l'approccio top-down per generare alberi di decisione.

Risposta:

L’approccio top-down per la costruzione degli alberi di decisione consiste nel partire dall’intero insieme dei dati e suddividerlo progressivamente in sottoinsiemi sempre più omogenei rispetto alla classe. In ogni passo si seleziona l’attributo migliore su cui effettuare la divisione, utilizzando una misura come l’information gain, e si crea un nodo dell’albero. Questo processo viene applicato ricorsivamente su ciascun sottoinsieme generato, fino a quando non si raggiungono condizioni di arresto. In questo modo si costruisce l’albero dalla radice verso le foglie, seguendo una logica di suddivisione progressiva dello spazio dei dati.

Quale è l'euristica di base per generare alberi di decisione?

Risposta:

L’euristica di base per la costruzione degli alberi di decisione consiste nello scegliere, ad ogni passo, l’attributo che consente di ottenere la migliore separazione dei dati rispetto alle classi. Questa scelta viene generalmente effettuata utilizzando l’information gain, che misura quanto una suddivisione riduce l’incertezza dei dati. L’obiettivo è quindi quello di massimizzare la purezza dei sottoinsiemi generati, rendendo ogni nodo il più possibile omogeneo rispetto alla classe.

Come avviene il processo di classificazione con alberi di decisione?

Risposta:

Il processo di classificazione con alberi di decisione avviene seguendo un percorso dalla radice fino a una foglia. Per classificare una nuova istanza, si analizza il valore degli attributi e si segue il ramo corrispondente a ogni nodo dell’albero. Questo processo continua fino a raggiungere una foglia, che contiene la classe predetta. In questo modo, la classificazione è ottenuta attraverso una sequenza di decisioni basate sugli attributi dell’istanza.

Quali sono le condizioni di terminazione per la generazione di alberi di decisione, utilizzando l'approccio top-down?

Risposta:

Il processo di costruzione dell’albero di decisione termina quando tutti gli esempi presenti in un nodo appartengono alla stessa classe, oppure quando non sono disponibili ulteriori attributi per effettuare la suddivisione. Un’altra condizione di arresto si verifica quando il

numero di esempi è troppo ridotto per consentire una divisione significativa. In questi casi, il nodo viene trasformato in una foglia e viene assegnata una classe, spesso sulla base della maggioranza degli esempi presenti.

Discutere i concetti di entropia e information gain.

Risposta:

L'entropia è una misura dell'incertezza o dell'impurità di un insieme di dati rispetto alla distribuzione delle classi. Un valore alto di entropia indica che le classi sono distribuite in modo uniforme, mentre un valore basso indica che il dataset è più omogeneo. L'information gain misura la riduzione dell'entropia ottenuta dividendo i dati secondo un determinato attributo. In altre parole, indica quanto un attributo è utile per classificare correttamente i dati. Durante la costruzione dell'albero di decisione, viene scelto l'attributo che massimizza l'information gain, poiché consente di ottenere la suddivisione più informativa.

A che categoria di classificatori appartiene il classificatore C45?

Risposta corretta:
Alberi di decisione

A che categoria di classificatori appartiene il classificatore ID3?

Risposta corretta:
Nessuna delle altre alternative

👉 (non è tra le opzioni, ma anche ID3 è un albero di decisione)

Con che tipo di attributi lavora il classificatore ID3?

Risposta corretta:
Nominali

Che cosa si usa come misura di rilevanza degli attributi nell'algoritmo ID3?

Risposta corretta:
Information gain

Quale fra le seguenti condizioni di terminazione della ricorsione dell'algoritmo ID3 non è corretta?

Risposta corretta:
Gli attributi sono vuoti

Che tipo di attributi può gestire senza pre-elaborazione il classificatore C45 rispetto al classificatore ID3?

Risposta corretta:
Numerici

Dopo la generazione di un albero con l'algoritmo C45, che ulteriore passo può essere effettuato per ridurre la possibilità di overtraining?

Risposta corretta:
Potatura

Come si identificano gli split point quando si utilizzano attributi reali?

Risposta:

Quando si utilizzano attributi reali, gli split point vengono identificati ordinando i valori dell'attributo e considerando come possibili punti di divisione i valori intermedi tra due esempi consecutivi appartenenti a classi diverse. Per ciascun possibile split viene calcolata una misura di qualità, come l'information gain, e viene scelto il punto che massimizza questa misura. In questo modo si trasforma un attributo continuo in una decisione binaria che permette di suddividere i dati in modo efficace.

Perché l'algoritmo C4.5 prevede una fase di potatura dell'albero? Come può essere fatta

Risposta:

L'algoritmo C4.5 prevede una fase di potatura per ridurre il rischio di overfitting, cioè per evitare che l'albero si adatti troppo ai dati di addestramento perdendo capacità di generalizzazione su nuovi dati. La potatura consiste nel semplificare l'albero eliminando rami che non contribuiscono significativamente alla capacità predittiva. Questo può essere fatto valutando le prestazioni dell'albero su un insieme di validazione oppure utilizzando stime statistiche dell'errore, sostituendo sottoalberi complessi con foglie che rappresentano la classe più probabile.

Discutere le principali differenze fra ID3 e C4.5.

Risposta:

ID3 e C4.5 sono entrambi algoritmi per la costruzione di alberi di decisione, ma presentano alcune differenze importanti. ID3 lavora principalmente con attributi nominali e utilizza l'information gain come criterio di selezione degli attributi, mentre C4.5 estende ID3 permettendo anche la gestione di attributi numerici e utilizzando una versione migliorata della misura di selezione, come il gain ratio. Inoltre, C4.5 introduce una fase di potatura dell'albero per ridurre l'overfitting, caratteristica che non è presente nella versione base di ID3. Questo rende C4.5 più robusto e più adatto a contesti reali rispetto a ID3.

Perfetto, continuiamo **stesso stile da esame, pulito e diretto**.

A che categoria di classificatori appartiene il classificatore CART?

Risposta corretta:
Alberi di decisione

Cosa utilizza l'algoritmo CART per misurare l'impurità di un database o di un generico insieme di transazioni

Risposta corretta:
L'indice di Gini

Quale misura di rilevanza è stata introdotta in una versione migliorata dell'algoritmo C45?

Risposta corretta:
Il gain ratio

Quale è la migliore misura di rilevanza degli attributi?

Risposta:

Non esiste una misura di rilevanza universalmente migliore in tutti i contesti, poiché la scelta dipende dalle caratteristiche del dataset e dal tipo di problema. L'information gain è semplice e intuitivo ma tende a favorire attributi con molti valori distinti. Il gain ratio cerca di correggere questo problema normalizzando l'information gain, rendendolo più equilibrato. L'indice di Gini, utilizzato in CART, è efficace dal punto di vista computazionale e spesso produce risultati comparabili o migliori in pratica. La scelta della misura dipende quindi dal compromesso tra accuratezza, complessità e tipo di dati disponibili.

Paragonare brevemente le misure di rilevanza degli attributi.

Risposta:

Le principali misure di rilevanza degli attributi differiscono per il modo in cui valutano la qualità di una suddivisione dei dati. L'information gain misura la riduzione dell'entropia e privilegia attributi che separano bene le classi, ma può essere influenzato negativamente da attributi con molti valori distinti. Il gain ratio introduce una normalizzazione per ridurre questo effetto, rendendo la selezione più bilanciata. L'indice di Gini, invece, misura l'impurità di un insieme e tende a essere più semplice da calcolare, risultando spesso più efficiente nei contesti pratici. Queste differenze rendono ciascuna misura più adatta a situazioni diverse.

Discutere come si utilizza l'indice di Gini per la selezione dell'attributo corrente significativo

Risposta:

L'indice di Gini viene utilizzato per valutare l'impurità di un insieme di dati rispetto alla distribuzione delle classi. Per ogni possibile attributo si considerano le suddivisioni che esso genera e si calcola il valore dell'indice di Gini per ciascun sottoinsieme risultante. Successivamente si combina il contributo dei vari sottoinsiemi per ottenere una misura complessiva dell'impurità dopo la suddivisione. L'attributo scelto è quello che minimizza l'indice di Gini, cioè quello che produce i sottoinsiemi più puri possibile. In questo modo si seleziona l'attributo che consente di ottenere la migliore separazione tra le classi.

I modelli bayesiani si usano per risolvere quali tipi di problemi?

Risposta corretta:
Classificazione

Quale è l'assunsione su cui si basano i classificatori Naive Bayes?

Risposta corretta:
L'indipendenza fra gli attributi che descrivono un oggetto quando la classe è nota

Su cosa si basano i classificatori bayesiani?

Risposta corretta:
Teoria della probabilità

In cosa consiste la creazione del modello di classificatore bayesiano?

Risposta:

La creazione di un modello di classificatore bayesiano consiste nella stima delle probabilità necessarie per applicare il teorema di Bayes alla classificazione. In particolare, si calcolano le probabilità a priori delle classi e le probabilità condizionate degli attributi rispetto alle classi utilizzando i dati di addestramento. Una volta stimati questi valori, il modello è in grado di calcolare la probabilità che una nuova istanza appartenga a ciascuna classe e assegnarla alla classe con probabilità più alta.

Introdurre il teorema di Bayes.

Risposta:

Il teorema di Bayes è una formula che consente di calcolare la probabilità di un evento a partire da informazioni note su eventi correlati. Esso permette di determinare la probabilità a posteriori di una classe dato un insieme di osservazioni, utilizzando la probabilità a priori della classe e la probabilità delle osservazioni condizionata alla classe. In forma generale, il teorema esprime la probabilità di una classe dato un insieme di attributi come proporzionale al prodotto tra la probabilità della classe e la probabilità degli attributi dato quella classe.

Discutere la differenza fra probabilità marginale, probabilità congiunta e probabilità condizionale.

Risposta:

La probabilità marginale rappresenta la probabilità di un singolo evento senza considerare altri fattori ed è ottenuta sommando o integrando su tutte le possibili configurazioni delle altre variabili. La probabilità congiunta descrive invece la probabilità che due o più eventi si verifichino contemporaneamente. La probabilità condizionale, infine, rappresenta la probabilità che un evento si verifichi dato che un altro evento è già avvenuto e consente di modellare la dipendenza tra variabili. Questi tre concetti sono strettamente collegati tra loro e costituiscono la base per l'applicazione del teorema di Bayes.

Discutere la principale differenza fra information gain e gain ratio.

Risposta:

L'information gain misura la riduzione dell'entropia ottenuta dividendo i dati secondo un attributo, ma tende a favorire attributi con molti valori distinti, anche se non particolarmente informativi. Il gain ratio è una versione migliorata che normalizza l'information gain tenendo

conto della suddivisione dei dati, riducendo così il bias verso attributi con molti valori. Di conseguenza, il gain ratio consente una selezione più equilibrata degli attributi rispetto all'information gain.

Come si possono stimare le probabilità condizionate da utilizzare nell'apprendimento dei parametri dei classificatori Naïve Bayes?

Risposta:

Le probabilità condizionate nei classificatori Naïve Bayes vengono stimate a partire dai dati di addestramento calcolando le frequenze relative degli attributi per ciascuna classe. In pratica, si conta quante volte un determinato valore di un attributo compare all'interno di una classe e si divide per il numero totale di esempi appartenenti a quella classe. In alcuni casi si applicano tecniche di smoothing, come la correzione di Laplace, per evitare problemi dovuti a probabilità nulle quando un certo valore non compare nei dati di addestramento.

Come avviene la classificazione di un nuovo punto quando si utilizza il classificatore KNN?

Risposta corretta:
Nessuna delle altre alternative

👉 (la risposta corretta sarebbe: si considerano i K vicini più prossimi e si assegna la classe più frequente, ma non è formulata correttamente nelle opzioni)

Quando si usano i classificatori lazy che tipo di apprendimento si usa per la costruzione del modello?

Risposta corretta:
Supervisionato

Quali fra i seguenti elementi non deve mai mancare quando si utilizza un classificatore KNN?

Risposta corretta:
Tutti e tre gli elementi specifici nelle altre alternative

In quali classificatori si può usare il majority voting pesato?

Risposta corretta:
KNN

Cosa è il rote classifier?

Risposta corretta:
Il più semplice classificatore lazy

Mostrare e discutere uno pseudocodice per un classificatore KNN.

Risposta:

Il classificatore KNN non prevede una vera fase di addestramento, ma utilizza direttamente il training set durante la fase di classificazione. Per classificare un nuovo punto, si calcola la distanza tra questo punto e tutti i punti presenti nel training set utilizzando una metrica definita. Successivamente si selezionano i K punti più vicini e si osservano le loro classi. Il punto viene quindi assegnato alla classe più frequente tra i vicini selezionati. Questo processo viene ripetuto per ogni nuova istanza da classificare, rendendo il metodo semplice ma computazionalmente costoso.

Discutere vantaggi e svantaggi dei classificatori KNN.

Risposta:

Il classificatore KNN presenta il vantaggio di essere semplice da implementare e di non richiedere una fase di addestramento esplicita, rendendolo flessibile e facilmente adattabile a diversi tipi di dati. Inoltre, può modellare relazioni complesse senza fare assunzioni forti sulla distribuzione dei dati. Tuttavia, presenta anche diversi svantaggi, tra cui l'elevato costo computazionale durante la fase di classificazione, poiché è necessario confrontare ogni nuovo punto con l'intero training set. Inoltre, le prestazioni dipendono fortemente dalla scelta del parametro K e della metrica di distanza, e il metodo è sensibile alla presenza di rumore e dati non bilanciati.

Discutere l'importanza della funzione di distanza nei classificatori KNN.

Risposta:

La funzione di distanza è un elemento fondamentale nel classificatore KNN, poiché determina quali punti del training set vengono considerati vicini al punto da classificare. Una scelta non appropriata della metrica può portare a selezionare vicini non rappresentativi, compromettendo la qualità della classificazione. La distanza deve quindi essere coerente con la natura dei dati e con il problema specifico, tenendo conto anche della scala degli

attributi, che spesso richiede una fase di normalizzazione per evitare che alcune variabili influenzino maggiormente il risultato.

Che cosa è il majority voting pesato?

Risposta:

Il majority voting pesato è una variante del metodo di classificazione utilizzato nel KNN in cui i vicini non contribuiscono tutti allo stesso modo alla decisione finale. Invece di assegnare lo stesso peso a ciascun vicino, si attribuisce un peso maggiore ai punti più vicini e un peso minore a quelli più lontani. In questo modo, i punti più simili al punto da classificare hanno un'influenza maggiore sulla decisione, migliorando spesso la qualità della classificazione.

In quali tipi di classificatori si può utilizzare il FOIL_gain?

Risposta corretta:
Classificatori a regole

Con riferimento ai classificatori basati su regole, cosa è la copertura di una regola?

Risposta corretta:
Frazione delle istanze nel database che soddisfano l'antecedente

Con riferimento ai classificatori basati su regole, cosa è l'accuratezza di una regola?

Risposta corretta:
Frazione delle istanze nel database che soddisfano antecedente e conseguente rispetto alla copertura

Con riferimento ai classificatori basati su regole, cosa sono le regole mutuamente esclusive?

Risposta corretta:
Un insieme di regole R è detto mutuamente esclusivo se nessuna coppia di regole può essere attivata dalla stessa istanza

Con riferimento ai classificatori basati su regole, cosa sono le regole esaustive?

Risposta corretta:
Un insieme di regole R ha una copertura esaustiva se esiste una regola per ogni combinazione di valori degli attributi

A che categoria di classificatori appartiene l'algoritmo RIPPER?

Risposta corretta:
Classificatori a regole

Quali sono le modalità di ordinamento delle regole? Perché potrebbe essere necessario ordinare le regole?

Risposta:

Le regole possono essere ordinate secondo diversi criteri, come l'accuratezza, la copertura oppure una combinazione delle due. L'ordinamento è importante perché, durante la classificazione, le regole vengono generalmente applicate in sequenza e la prima regola che risulta soddisfatta determina la classe assegnata all'istanza. Per questo motivo è necessario stabilire un ordine che privilegi le regole più affidabili, in modo da migliorare la qualità complessiva della classificazione ed evitare conflitti tra regole.

Discutere brevemente l'algoritmo di classificazione RIPPER

Risposta:

L'algoritmo RIPPER è un metodo per la generazione di classificatori basati su regole che costruisce un insieme di regole in modo incrementale. Il processo inizia generando regole che coprono le istanze di una determinata classe, cercando di massimizzare la qualità della regola attraverso misure come il FOIL gain. Successivamente, le regole vengono semplificate attraverso una fase di potatura per evitare l'overfitting. Il procedimento viene ripetuto fino a coprire tutte le istanze del dataset. L'algoritmo è noto per essere efficiente e per produrre regole interpretabili.

A cosa serve il FOIL_gain?

Risposta:

Il FOIL_gain è una misura utilizzata per valutare la qualità di una regola durante il processo di costruzione nei classificatori basati su regole. Serve a determinare quanto una condizione aggiunta all'antecedente di una regola migliori la sua capacità di discriminare correttamente le istanze positive da quelle negative. In pratica, guida la selezione delle condizioni migliori

da aggiungere alla regola, favorendo quelle che aumentano l’accuratezza della classificazione.

Discutere la differenza fra metodi diretti e indiretti per la generazione di regole

Risposta:

I metodi diretti generano regole di classificazione direttamente a partire dai dati, costruendo le regole una alla volta senza passare attraverso altre strutture intermedie. I metodi indiretti, invece, derivano le regole da altri modelli, come gli alberi di decisione, trasformando i percorsi dell’albero in regole. La differenza principale sta quindi nel fatto che i metodi diretti costruiscono le regole in modo esplicito durante il processo di apprendimento, mentre quelli indiretti le ottengono come rappresentazione alternativa di un modello già costruito.

Cosa deve simulare un percettrone?

Risposta corretta:
Il funzionamento di un neurone

Su cosa si base l'algoritmo di classificazione RIPPER?

Risposta corretta:
Sequential covering

Che cosa è il percettrone?

Risposta corretta:
L'elemento base delle reti neurali artificiali

Cosa significa addestrare un percettrone?

Risposta corretta:
Nessuna delle altre alternative

👉 (la risposta corretta sarebbe: determinare i pesi dei collegamenti, ma non è formulata bene nelle opzioni)

Di che tipo è l'uscita del percettrone?

Risposta corretta:
Binaria

Come si chiama l'algoritmo di apprendimento dei parametri di un percettrone?

Risposta corretta:
Deltra rule

Quali sono i parametri caratteristici di una rete neurale artificiale?

Risposta corretta:
L'insieme dei neuroni, l'insieme dei pesi associati ai collegamenti, l'insieme delle soglie o dei livelli di attivazione

In cosa consiste l'addestramento di un percettrone? Discutere l'algoritmo delta rule.

Risposta:

L’addestramento di un percettrone consiste nella determinazione dei pesi associati agli ingressi in modo tale da classificare correttamente gli esempi del training set. Questo avviene attraverso un processo iterativo in cui il modello confronta l’uscita prodotta con quella desiderata e modifica i pesi per ridurre l’errore. L’algoritmo delta rule rappresenta il metodo con cui vengono aggiornati i pesi, modificandoli proporzionalmente all’errore commesso e al valore degli ingressi. In questo modo, il percettrone apprende progressivamente una funzione di decisione che separa le classi.

Discutere le principali funzioni di attivazione che possono essere usate nei percettroni.

Risposta:

Le funzioni di attivazione nei percettroni servono a determinare l’uscita del neurone sulla base della combinazione pesata degli ingressi. La funzione più semplice è quella a soglia, che produce un’uscita binaria in base al superamento di un certo valore. Esistono anche funzioni più avanzate come la funzione sigmoide, che restituisce valori continui tra zero e uno, e la funzione tangente iperbolica, che permette di ottenere valori sia positivi che negativi. La scelta della funzione di attivazione influisce sul comportamento del modello e sulla sua capacità di apprendere relazioni più complesse.

Cosa è il percettrone? Disegnare la sua struttura e discutere i suoi parametri.

Risposta:

Il percettrone è un modello matematico che rappresenta un neurone artificiale ed è alla base delle reti neurali. Esso riceve in ingresso un insieme di valori, ciascuno associato a un peso, e calcola una combinazione lineare di questi ingressi. Il risultato viene poi passato a una funzione di attivazione che produce l'uscita. I parametri principali del percettrone sono i pesi associati agli ingressi e la soglia di attivazione, che determina quando il neurone si attiva. La struttura è composta quindi da ingressi, pesi, una funzione di aggregazione e una funzione di attivazione.

In cosa consiste la progettazione di una rete neurale?

Risposta:

La progettazione di una rete neurale consiste nella definizione della sua struttura e dei suoi parametri in modo da adattarla al problema da risolvere. Questo include la scelta del numero di livelli, del numero di neuroni per ciascun livello, della funzione di attivazione e dell'algoritmo di apprendimento. Inoltre, è necessario stabilire come addestrare la rete e come valutare le sue prestazioni. Una buona progettazione è fondamentale per ottenere un modello efficace e capace di generalizzare su nuovi dati.

Quali sono le principali componenti di una rete neurale?

Risposta:

Le principali componenti di una rete neurale sono i neuroni, che rappresentano le unità di elaborazione, i collegamenti tra neuroni, ciascuno associato a un peso, e le funzioni di attivazione che determinano l'uscita dei neuroni. A queste si aggiungono eventuali soglie o bias che permettono di modificare il comportamento del neurone. L'insieme di queste componenti consente alla rete di apprendere e modellare relazioni complesse tra i dati.

Come avviene la generazione dei pesi iniziali nell'algoritmo backpropagation?

Risposta corretta:
A caso

Quale fra le seguenti caratteristiche non è tipica di una rete neurale feedforward?

Risposta corretta:
Presenza di feedback

Quale fra le seguenti caratteristiche non è tipica di una rete neurale feedforward?

Risposta corretta:
Presenza di stato interno

Quante uscite in genere si usano nelle reti neurali feedforward quando si vuole risolvere un problema di classificazione con C classi?

Risposta corretta:
C

Che problemi possono essere risolti con le reti neurali feedforward?

Risposta corretta:
Classificazione

Come si chiama l'algoritmo di apprendimento delle reti feedforward?

Risposta corretta:
Back propagation

Cosa sono le epoche di addestramento di una rete feedforward?

Risposta:

Le epoche di addestramento rappresentano il numero di iterazioni complete sul dataset di training durante le quali la rete neurale aggiorna i propri pesi. In ogni epoca, tutti gli esempi vengono utilizzati per calcolare l'errore e migliorare progressivamente il modello. L'aumento del numero di epoche consente alla rete di apprendere meglio, ma un numero eccessivo può portare a fenomeni di overfitting.

Come si possono utilizzare le reti feedforward per la classificazione?

Risposta:

Le reti feedforward possono essere utilizzate per la classificazione associando ogni neurone di output a una classe specifica. Durante l'addestramento, la rete impara a produrre valori elevati per la classe corretta e bassi per le altre. In fase di utilizzo, dato un nuovo input, si calcolano le uscite della rete e si assegna l'istanza alla classe corrispondente al valore più alto.

Come avviene l'apprendimento di una rete feedforward?

Risposta:

L'apprendimento avviene attraverso l'algoritmo di backpropagation, che consiste in una fase di propagazione in avanti per calcolare l'uscita e una fase di propagazione all'indietro dell'errore per aggiornare i pesi. I pesi vengono modificati in modo iterativo per ridurre la differenza tra l'uscita prodotta e quella desiderata, permettendo alla rete di migliorare le proprie prestazioni nel tempo.

Disegnare e discutere lo schema e i parametri di una rete feedforward.

Risposta:

Una rete feedforward è composta da più strati di neuroni organizzati in modo sequenziale: uno strato di input, uno o più strati nascosti e uno strato di output. Ogni neurone riceve in ingresso valori pesati, li combina e applica una funzione di attivazione per produrre un'uscita. I parametri principali della rete sono i pesi associati alle connessioni, le soglie o bias e la struttura della rete stessa, cioè il numero di strati e di neuroni. Questa organizzazione consente di modellare relazioni complesse tra i dati.

Perché sono state introdotte le reti multi-strato? Non bastava il semplice percettrone?

Risposta:

Il percettrone semplice è in grado di risolvere solo problemi linearmente separabili, mentre molti problemi reali presentano relazioni non lineari tra le variabili. Le reti multi-strato sono state introdotte proprio per superare questa limitazione, permettendo di apprendere funzioni più complesse grazie alla presenza di strati nascosti. In questo modo, le reti neurali diventano capaci di risolvere problemi che il percettrone da solo non sarebbe in grado di gestire.

Cosa è la matrice di confusione? Discutere sia il caso di classificazione binaria sia il caso di classificazione multi-classe.

Risposta:

La matrice di confusione è una tabella che riassume le prestazioni di un classificatore confrontando le classi reali con quelle predette. Nel caso binario, la matrice è composta da quattro elementi: veri positivi, veri negativi, falsi positivi e falsi negativi. Nel caso multi-classe, la matrice si estende a più righe e colonne, una per ciascuna classe, permettendo di analizzare in dettaglio gli errori di classificazione tra tutte le categorie.

Discutere le principali misure utilizzate per la valutazione di classificatori?

Risposta:

Le principali misure includono l'accuracy, che rappresenta la percentuale di predizioni corrette, e metriche più specifiche come precision e recall, che valutano rispettivamente l'affidabilità delle predizioni positive e la capacità di individuare correttamente i casi positivi. L'F1-score combina queste due misure in un unico valore, mentre altre metriche come l'AUC forniscono una valutazione complessiva delle prestazioni indipendentemente dalla soglia di classificazione.

Quali sono i problemi e le possibili soluzioni che si possono incontrare nell'addestramento di una rete feedforward?

Risposta:

Tra i principali problemi si trovano l'overfitting, la convergenza lenta e la difficoltà nella scelta dei parametri. L'overfitting può essere ridotto utilizzando tecniche come la regolarizzazione o l'early stopping. La convergenza può essere migliorata scegliendo opportunamente il learning rate e inizializzando correttamente i pesi. Inoltre, è importante utilizzare dati di validazione per monitorare le prestazioni durante l'addestramento.

Come si può effettuare il confronto fra due o più classificatori? Che tipo di test statistici si possono usare?

Risposta:

Il confronto tra classificatori può essere effettuato valutando le loro prestazioni su uno stesso dataset e utilizzando metriche comuni. Per verificare se le differenze sono significative, si utilizzano test statistici come il t-test, il test di Wilcoxon o il test di McNemar. Questi strumenti permettono di stabilire se un classificatore è effettivamente migliore di un altro o se la differenza è dovuta al caso.

Discutere l'importanza dell'area sotto la curva ROC (AUC).

Risposta:

L'AUC rappresenta una misura sintetica della capacità di un classificatore di distinguere tra classi positive e negative. Un valore elevato indica una buona capacità discriminativa del modello. Questa misura è particolarmente utile perché non dipende da una specifica soglia di classificazione e consente di confrontare diversi modelli in modo più robusto.

Cosa sono la sensibilità e la specificità?

Risposta:

La sensibilità misura la capacità del modello di identificare correttamente i casi positivi, mentre la specificità misura la capacità di riconoscere correttamente i casi negativi. Queste due misure sono fondamentali per valutare le prestazioni di un classificatore in contesti in cui è importante distinguere tra errori di tipo diverso.

Cosa è e a cosa serve la curva ROC? Come si individuano i punti che la formano?

Risposta:

La curva ROC è un grafico che rappresenta il compromesso tra il tasso di veri positivi e il tasso di falsi positivi al variare della soglia di classificazione. Serve a valutare le prestazioni del modello e a scegliere la soglia più appropriata. I punti della curva vengono ottenuti calcolando questi tassi per diversi valori della soglia.

Quali potrebbero essere i criteri di stop per l'addestramento di una rete feedforward?

Risposta:

I criteri di stop possono includere il raggiungimento di un numero massimo di epoche, la stabilizzazione dell'errore oppure l'assenza di miglioramenti significativi nelle prestazioni sul validation set. Un criterio molto utilizzato è l'early stopping, che interrompe l'addestramento quando le prestazioni iniziano a peggiorare sui dati di validazione, evitando così l'overfitting.

Quale è la formula per la Recall, utilizzata come metrica per valutare la bontà di un classificatore binari?

Risposta corretta:
R = TP/(TP+FN)

Quale metrica è più consigliata quando si vuole confrontare la bontà di due o più modelli per la classificazione binaria?

Risposta corretta:
AUC

Quale è l'area associata alla curva ROC di un classificatore random?

Risposta corretta:
Nessuna delle altre alternative

👉 (il valore corretto è 0,5, ma non è presente tra le opzioni)

Cosa viene riportato sugli assi di una curva ROC?

Risposta corretta:
TPR, FPR

Quando è sconsigliato utilizzare l'accuratezza come metrica per valutare la bontà di un classificatore?

Risposta corretta:
Se le classi sono sbilanciate

Quale strumento può essere utilizzato per valutare la bontà di un classificatore binario?

Risposta corretta:
Matrice di confusione

Quale è la formula per la Precisione, utilizzata come metrica per valutare la bontà di un classificatore binari?

Risposta corretta:
P = TP/(TP+FP)

Quale è stata la soluzione proposta per soddisfare i requisiti del progetto?

Risposta (modello corretto):

La soluzione proposta per soddisfare i requisiti del progetto consiste nell'adozione di un approccio basato su tecniche di data mining, in cui i dati vengono prima preprocessati e successivamente analizzati attraverso specifici algoritmi. In particolare, è stato utilizzato un modello di analisi in grado di estrarre pattern significativi dai dati e supportare il processo decisionale. La soluzione integra diverse fasi, tra cui la preparazione dei dati, la selezione degli algoritmi più appropriati e la valutazione dei risultati, garantendo così il soddisfacimento dei requisiti iniziali del progetto.

Quali sono stati i risultati raggiunti con la soluzione proposta per soddisfare i requisiti del progetto?

Risposta (modello corretto):

I risultati ottenuti mostrano che la soluzione proposta è stata in grado di soddisfare i requisiti del progetto, consentendo di individuare pattern significativi e migliorare la qualità delle decisioni. In particolare, l'applicazione degli algoritmi ha permesso di ottenere modelli con buone prestazioni in termini di accuratezza e capacità di generalizzazione. Inoltre, la soluzione ha dimostrato di essere efficace anche dal punto di vista computazionale, fornendo risultati utili e interpretabili nel contesto applicativo considerato.